esprit

Se former autrement

HONORIS UNITED UNIVERSITIES

2024 / 2025

SPÉCIALITÉ : Data Science

Modélisation d'un Géocodeur Intelligent pour la Logistique Urbaine

Réalisé par : ▪ Mme. Labidi Salma

Encadré par : ▪ Mr. Rammah Ali

armada

delivery solutions

EUR-ACE® Délivrée par la Commission des Titres d'Ingénieur

CONFÉRENCE DES GRANDES ÉCOLES

cdio

AUF Agence Universitaire de la Francophonie

IFGU

Dédicaces

À mes **chers parents**, pour leur amour inconditionnel, leurs encouragements et leurs sacrifices qui m'ont permis d'arriver jusqu'ici.

À ma sœur **Souha**, pour sa présence et son soutien constants.

À mes amies, pour leur amitié et leurs encouragements.

À **Ramah Ali**, mon encadrant académique, pour son accompagnement rigoureux, ses conseils avisés et sa disponibilité tout au long de ce travail.

À l'équipe **Armada Delivery Solutions** et à **Monsieur Bouraoui, Head of Engineers**, pour la confiance accordée et le cadre professionnel enrichissant offert durant ce projet.

Salma Labidi

Remerciements

Avant tout, je rends grâce à Dieu Tout-Puissant qui m'a donné la santé, la patience et la persévérance nécessaires pour mener à bien ce travail.

Je tiens à exprimer ma profonde gratitude à mon encadrant académique, **Ramah Ali**, pour son suivi rigoureux, ses précieux conseils et son orientation constructive tout au long de ce projet.

Mes remerciements vont également à **Armada Delivery Solutions**, qui m'a offert l'opportunité d'intégrer leur environnement de travail et de contribuer à un projet à fort impact dans le domaine de la logistique urbaine.

Je remercie particulièrement **M. Bouraoui**, Head of Engineers, pour sa disponibilité, son soutien technique et ses recommandations pertinentes qui ont grandement enrichi ce projet.

Enfin, je n'oublie pas tous ceux, de près ou de loin, qui ont contribué à la réussite de ce travail, et je leur adresse mes plus sincères remerciements.

Table des matières

Introduction générale **1**

1 Contexte du projet **3**

1.1 Introduction 3

1.2 Présentation de l'organisme d'accueil 3

1.2.1 Organisme d'accueil : 3

1.2.2 Domaines d'activités 5

1.3 Présentation du projet 6

1.3.1 Cadre de projet 6

1.3.2 Problématique 6

1.3.3 Étude de l'existant 7

1.3.4 Solution proposée 11

1.4 Méthodologie de travail et planification 12

1.4.1 Introduction 12

1.4.2 Méthodologie Scrum 12

1.4.3 Méthodologie Data Science (CRISP-DM) 14

1.5 Conclusion 16

2 Compréhension des métiers **17**

2.1 Introduction 17

2.2 Le géocodage et son importance dans la logistique 17

2.2.1 Définition du géocodage 17

2.2.2 Utilité du géocodage dans la livraison du dernier kilomètre 18

2.2.3 Spécificités et défis au Koweït 19

2.2.4 Enjeux stratégiques du géocodage 20
2.3 Détermination des objectifs métiers 21
2.4 Évaluation de la situation actuelle 21
2.5 Détermination des objectifs data science 22
2.6 Élaboration du plan de projet 22
2.7 Outils et technologies utilisés 23
2.7.1 Environnements de développement 23
2.7.2 Bibliothèques de traitement et visualisation 23
2.7.3 Bibliothèques de modélisation et d'évaluation . . . 23
2.7.4 Bases de données et stockage 24
2.7.5 Traitement du langage et embeddings 24
2.7.6 Gestion de projet et collaboration 24
2.8 Conclusion 25

3 Compréhension des données 26
3.1 Introduction 26
3.2 Collecte initiale des données 26
3.2.1 Source et extraction 26
3.2.2 Exemple de document 27
3.3 Description des données 27
3.3.1 Champs principaux 27
3.3.2 Résumé numérique des champs 28
3.3.3 Distribution des blocs et rues 28
3.3.4 Couverture géographique 29
3.4 Exploration des données 29
3.4.1 Zones les plus fréquentes 29
3.4.2 Anomalies observées 31
3.5 Qualité des données 31
3.5.1 Complétude 31
3.5.2 Cohérence 31
3.5.3 Pertinence 31
3.6 Conclusion 32

4 Data Preparation **33**
4.1 Introduction 33
4.2 Data Cleaning et gestion des valeurs manquantes 34
4.2.1 Taux de complétude des champs 34
4.2.2 Normalisation des champs textuels 34
4.2.3 Nettoyage des numéros de bâtiment 35
4.2.4 Création de variables indicatrices 35
4.2.5 Encodage spatial avec Geohash 36
4.3 Équilibrage spatial et pondération 36
4.3.1 Kernel Density Estimation (KDE) 36
4.3.2 Définition des poids d'échantillonnage 36
4.3.3 Ajustement par gouvernorat 37
4.4 Feature Engineering 37
4.4.1 Features géographiques hiérarchiques 37
4.4.2 Features numériques 38
4.4.3 TF-IDF Features 38
4.4.4 Sentence Embeddings 38
4.5 Construction du dataset final 39
4.6 Sauvegarde et reproductibilité 39
4.7 Conclusion 40

5 Modélisation et Évaluation **41**
5.1 Introduction 41
5.2 Stratégie de modélisation 41
5.3 Métriques d'évaluation détaillées 42
5.4 Enhanced *XGBoost* Geocoder 42
5.4.1 Rappel théorique 42
5.4.2 Features utilisées 43
5.4.3 Justification du choix 43
5.4.4 Procédure d'entraînement 43
5.4.5 Résultats empiriques 44
5.4.6 Analyse qualitative 44
5.5 Hybrid *XGBoost + FAISS* Geocoder 44

5.5.1 Composants et principes 44
5.5.2 Pourquoi FAISS ? 45
5.5.3 Résultats empiriques 46
5.5.4 Interprétation 46
5.6 Visualisations et interprétations 46
5.6.1 Distribution des erreurs géographiques 47
5.6.2 Courbe cumulative des erreurs (CDF) 48
5.6.3 Visualisation géographique des prédictions 49
5.6.4 Synthèse des visualisations 49
5.7 Conclusion 50

6 Déploiement **51**
6.1 Introduction 51
6.2 Architecture fonctionnelle du déploiement 51
6.3 Scénarios d'utilisation 53
6.3.1 Avant l'intégration du géocodeur 53
6.3.2 Après l'intégration du géocodeur 54
6.4 Appels API et réponses 55
6.5 Bénéfices concrets du déploiement 55
6.6 Conclusion 55

Conclusion Générale **57**

Table des figures

1.1 Logo Armada Delivery 4
1.2 Processus global de livraison + géocodage 12
1.3 Phases de la méthodologie Scrum 14
1.4 Phases de la méthodologie CRISP-DM 15

2.1 Un schéma du processus de géocodage 19
2.2 Carte du Koweït mettant en évidence les zones urbaines denses (Salmiya, Hawalli, Farwaniya, etc.) où les problèmes d'adressage et de livraison sont particulièrement critiques. 20
2.3 Logos de Python 23
2.4 Logo de MongoDB utilisé pour le stockage 24
2.5 Logos des outils de gestion de projet et collaboration . . . 24

3.1 Un exemple de document extrait 27
3.2 Distribution par gouvernorat 29
3.3 Top 10 des zones les plus fréquentes 30
3.4 Top 10 des zones les plus fréquentes(%) 30

4.1 Distribution des poids d'échantillonnage (`sample_weight`) 37
4.2 Dataset final 39

5.1 Distribution des erreurs géographiques (histogramme) pour XGBoost et Hybrid XGBoost+FAISS. 47
5.2 Courbe cumulative (CDF) des erreurs de localisation — proportion d'adresses sous un rayon donné. 48
5.3 Visualisation géographique : positions réelles (bleu) vs prédictions (rouge) pour un échantillon représentatif. 49

6.1 Architecture fonctionnelle du déploiement. 53
6.2 Ancienne interface d'Ettijahet : saisie obligatoire des coordonnées GPS. 54
6.3 Nouvelle interface d'Ettijahet : saisie textuelle des adresses avec bascule (toggle) entre GPS et adresses. 54

Liste des tableaux

1.1 Comparaison des solutions de géocodage existantes 10

3.1 Résumé numérique des champs principaux 28

4.1 Taux de complétude des champs principaux 34

Introduction générale

Le monde contemporain est marqué par une évolution technologique rapide qui transforme en profondeur la société et les modes de fonctionnement des entreprises. La révolution numérique a ouvert la voie à de nouvelles méthodes de travail et à l'émergence de solutions innovantes dans des domaines variés tels que la communication, la santé, l'éducation, la finance et la logistique.

Parmi les avancées technologiques les plus influentes, l'intelligence artificielle et la science des données occupent une place prépondérante. Ces disciplines permettent aujourd'hui d'exploiter des volumes massifs d'informations afin de développer des systèmes intelligents capables d'assister l'être humain dans des tâches complexes. Grâce à elles, il est désormais possible d'optimiser des processus, d'automatiser certaines prises de décision et d'apporter des solutions plus précises et rapides que celles générées par l'homme seul.

Dans ce contexte, le secteur de la logistique connaît une transformation notable. L'essor du commerce en ligne et la généralisation des services de livraison ont accentué le besoin en solutions fiables, rapides et efficaces. Les entreprises cherchent ainsi à améliorer la planification des trajets, à réduire les délais et à offrir une meilleure expérience client. Ces enjeux ne peuvent être atteints qu'à travers l'utilisation d'outils technologiques avancés intégrant la géolocalisation et le géocodage.

Ces technologies jouent un rôle crucial puisqu'elles permettent de convertir des adresses en coordonnées géographiques exploitables, de calculer des distances, d'estimer des temps de parcours et d'optimiser les itinéraires. Elles sont aujourd'hui au cœur des systèmes de mobilité et de gestion des

livraisons, mais leur efficacité dépend fortement de la qualité des données disponibles et de l'adaptation aux spécificités locales.

C'est dans ce cadre général, marqué par l'interconnexion entre les technologies émergentes et les besoins concrets du monde professionnel, que s'inscrit le présent travail. Celui-ci illustre l'importance de l'innovation numérique et met en lumière la contribution des systèmes intelligents à l'amélioration des processus métiers.

Chapitre 1

Contexte du projet

1.1 Introduction

Ce chapitre introductif est consacré pour la présentation de l'organisme d'accueil, le cadre général du projet, à savoir l'étude et la critique de l'existant, la présentation de la problématique ainsi que la solution proposée, et finalement nous relevons la méthodologie optée pour la planification de ce projet.

1.2 Présentation de l'organisme d'accueil

1.2.1 Organisme d'accueil :

Armada Delivery Solutions, une entreprise technologique innovante spécialisée dans la logistique urbaine et les services de livraison à la demande. Fondée en 2016 et ayant son siège à Kuwait City, l'entreprise s'est rapidement imposée comme un acteur majeur de la livraison du dernier kilomètre dans la région du Golfe.

Armada Delivery met à disposition une plateforme numérique qui connecte en temps réel les demandes des clients (restaurants, commerces, e-commerce, particuliers) avec les ressources logistiques disponibles, qu'il s'agisse de chauffeurs indépendants ou de flottes de véhicules. Grâce à cette approche, l'entreprise contribue à rendre les livraisons plus rapides, plus fiables et

mieux adaptées aux besoins du marché local.

Au-delà de son rôle de prestataire logistique, Armada se distingue également comme une entreprise technologique. Elle développe des solutions logicielles avancées permettant le suivi des livraisons, la gestion des flottes, l'optimisation des itinéraires et l'intégration via des API. Ces outils sont utilisés non seulement par ses propres équipes, mais également par ses partenaires commerciaux qui souhaitent bénéficier d'une meilleure maîtrise de leurs opérations.

Si l'entreprise est née au Koweït, elle a progressivement élargi son champ d'action et dispose aujourd'hui d'une présence régionale, notamment en Tunisie, Arabie Saoudite et au Bahreïn. Par ailleurs, Armada Delivery a choisi la Tunisie comme base pour une partie de son équipe technique. Ce choix s'explique par la disponibilité de compétences qualifiées dans le domaine du développement logiciel et de la data science, et témoigne de la volonté de l'entreprise de s'appuyer sur des talents internationaux pour soutenir sa croissance.

En quelques années, Armada Delivery a su bâtir une réputation solide dans le domaine de la logistique intelligente, en conciliant innovation technologique et exigence opérationnelle pour répondre aux besoins croissants d'un marché en pleine expansion.



FIGURE 1.1 – Logo Armada Delivery

1.2.2 Domaines d'activités

Armada Delivery Solutions exerce ses activités principalement dans le domaine de la logistique urbaine et de la livraison à la demande, en mettant l'accent sur l'innovation technologique et l'optimisation des processus. Ses domaines d'activités peuvent être détaillés comme suit :

1. **Logistique urbaine et livraison du dernier kilomètre :** Armada Delivery assure le transport et la livraison rapide de produits commandés par des clients B2B et B2C. La société prend en charge la planification des trajets, la gestion des commandes et le suivi des livraisons en temps réel, afin de garantir une expérience client fiable et efficace.
2. **Développement et déploiement de solutions technologiques :** L'entreprise conçoit des outils logiciels avancés, incluant des applications web pour les commerçants et des applications mobiles pour les livreurs, permettant de gérer les plannings, suivre les itinéraires, et optimiser les ressources logistiques. Ces solutions intègrent notamment des fonctionnalités de géolocalisation et de calcul des distances.
3. **Optimisation opérationnelle et gestion des flottes :** Armada Delivery propose des systèmes intelligents de gestion des flottes et de planification automatisée des itinéraires, permettant de réduire les délais de livraison, d'améliorer l'utilisation des ressources et de minimiser les coûts opérationnels.
4. **Intégration via API et services aux partenaires :** L'entreprise offre la possibilité aux partenaires commerciaux d'intégrer directement ses fonctionnalités logistiques à leurs propres systèmes via des API. Cette approche facilite la coordination, le suivi des commandes et la centralisation des informations.
5. **Innovation et exploitation des données :** Armada Delivery s'appuie sur la data science et l'intelligence artificielle pour analyser les données de livraison réelles, développer des algorithmes de

géocodage et améliorer la précision des estimations de temps et de distance.

6. **Expansion régionale et stratégie internationale :** Au-delà de son activité au Koweït, Armada Delivery s'est étendue à d'autres marchés de la région, notamment l'Arabie Saoudite, le Bahreïn et la Tunisie, renforçant ainsi sa présence commerciale et son expertise technique.

1.3 Présentation du projet

1.3.1 Cadre de projet

Le projet réalisé durant mon stage chez **Armada Delivery Solutions** s'inscrit dans le cadre de l'amélioration des services logistiques proposés par la plateforme **Armada Ettijaht**. Cette plateforme permet aux clients, qu'il s'agisse de restaurants, commerces ou particuliers, d'obtenir des estimations précises de temps et de distance pour leurs livraisons.

L'objectif principal du projet est de développer un **geocoder spécifique au Koweït**, capable de transformer les adresses textuelles en coordonnées géographiques (latitude et longitude) avec une grande précision. Ce geocoder doit remplacer l'utilisation de l'API Google Maps, qui présentait des limitations importantes telles que l'imprécision pour certaines adresses locales, une couverture incomplète du territoire koweïtien et une dépendance à un service externe avec des contraintes de coût et de quotas.

Le projet a ainsi pour but de fournir un outil autonome, fiable, précis et facilement intégrable dans la plateforme existante, permettant d'améliorer la qualité des estimations et la satisfaction des clients.

1.3.2 Problématique

Dans le contexte actuel de croissance rapide du commerce en ligne et des services de livraison à domicile, la précision du géocodage est devenue un enjeu stratégique pour les entreprises logistiques. Une estimation incorrecte

des coordonnées géographiques peut entraîner :

— Des erreurs dans le calcul des distances et des temps de parcours.
— Des itinéraires inefficaces pour les livreurs, augmentant les coûts opérationnels.
— Une insatisfaction des clients due à des retards ou des livraisons incorrectes.

Les solutions existantes, telles que Google Maps, présentent plusieurs limites :

— Imprécision sur certaines adresses locales ou récemment créées.
— Couverture incomplète du territoire koweïtien.
— Dépendance à un service externe, entraînant des coûts supplémentaires et des restrictions sur le nombre de requêtes.

Ainsi, la problématique consiste à développer un geocoder interne **fiable, précis et indépendant**, capable de couvrir l'ensemble des adresses du Koweït et de s'intégrer parfaitement à la plateforme Armada Ettijaht.

1.3.3 Étude de l'existant

Avant de concevoir un géocodeur interne, il était nécessaire d'analyser les solutions de géocodage déjà disponibles sur le marché. L'objectif de cette étude était double :

1. Identifier les forces et faiblesses des outils existants afin de comprendre pourquoi ils ne suffisent pas aux besoins d'Armada Delivery.
2. Mettre en évidence les contraintes spécifiques au contexte géographique et culturel du Koweït et de la Tunisie, où les systèmes d'adressage classiques sont souvent incomplets ou informels.

Google Maps API : Google Maps est la solution la plus répandue et largement intégrée dans les applications de mobilité et de livraison. Elle offre une base de données très riche, une grande rapidité d'accès et des fonctionnalités variées (géocodage direct et inverse, calcul d'itinéraires, points d'intérêt, etc.). Toutefois, cette solution présente plusieurs limites :

- **Coût élevé** : l'utilisation massive des API entraîne des frais considérables pour une entreprise de livraison qui effectue des milliers de requêtes par jour.
- **Quotas et restrictions** : les appels aux API sont soumis à des quotas, ce qui peut limiter la scalabilité d'un système logistique en pleine croissance.
- **Précision variable** : dans les zones urbaines non cartographiées de manière formelle, notamment certains quartiers périphériques du Koweït ou des villes tunisiennes, la localisation peut être approximative voire erronée.
- **Dépendance technologique** : Armada perdrait une part de contrôle stratégique en confiant à Google la gestion de ses données sensibles liées à la localisation et aux trajets.

Bing Maps et OpenStreetMap (OSM) : Ces deux alternatives constituent des solutions intéressantes pour diversifier les sources de données cartographiques. Bing Maps dispose d'une interface similaire à Google Maps et OSM est une base de données collaborative qui évolue grâce aux contributions des utilisateurs. Cependant :

- **Problèmes de couverture** : au Koweït et en Tunisie, certaines zones sont mal représentées, notamment les nouvelles zones résidentielles et industrielles.
- **Incohérences dans les adresses** : les formats d'adresses ne sont pas standardisés, ce qui rend difficile leur intégration dans un algorithme automatisé de géocodage.
- **Personnalisation limitée** : même si OSM permet des mises à jour, leur intégration dans un système interne en temps réel reste complexe.

Here Maps et Mapbox : Ces solutions se positionnent comme des concurrents directs de Google. Elles offrent des SDK modernes et de bonnes performances dans certains marchés. Toutefois, elles partagent plusieurs limites similaires :

- **Coût et modèles économiques proches de Google**.
- **Précision non garantie** dans les marchés émergents, en particulier en Afrique du Nord et au Moyen-Orient.
- **Dépendance externe** : la donnée n'est pas maîtrisée en interne.

Solutions internes d'autres entreprises logistiques : Certaines grandes entreprises (par exemple Amazon Logistics, Aramex ou Talabat) ont investi dans leurs propres systèmes de géocodage adaptés à leur zone d'activité. Cependant :

- Ces solutions ne sont pas accessibles publiquement et sont développées pour un usage interne exclusif.
- Elles sont généralement limitées à un pays ou à une région précise.
- Leur intégration externe est très compliquée, voire impossible.

Contraintes stratégiques et régionales : En plus des aspects techniques, Armada doit aussi considérer :

- **Le contexte koweïtien et tunisien** : de nombreuses adresses sont encore basées sur des repères visuels (« près de la mosquée », « derrière la pharmacie », etc.) plutôt que sur des coordonnées standard.
- **La croissance rapide du e-commerce et du food delivery** : qui exige des solutions scalables et hautement précises.
- **L'autonomie stratégique** : la dépendance à un service externe peut poser problème si les coûts augmentent ou si l'accès est restreint pour des raisons politiques ou économiques.

Solution	**Avantages**	**Limites**
Google Maps	Couverture mondiale, rapidité, documentation riche	Coût élevé, quotas, dépendance externe, précision limitée en zones locales
Bing Maps	Interface similaire à Google, bonne intégration avec produits Microsoft	Couverture limitée au Koweït et en Tunisie, précision variable
OpenStreetMap	Gratuit, collaboratif, modifiable	Manque de standardisation, lenteur de mise à jour, faible précision locale
Here Maps	Bonne documentation, SDK moderne	Coût proche de Google, couverture régionale limitée
Mapbox	Flexibilité, visualisation personnalisée	Dépendance externe, précision variable, coût
Solutions internes	Adaptées au contexte local, indépendance des données	Fermées au public, difficiles à intégrer, limitées géographiquement

TABLE 1.1 – Comparaison des solutions de géocodage existantes

Cette analyse démontre qu'aucune solution existante ne répond parfaitement aux besoins spécifiques d'Armada Delivery. Les problèmes récurrents sont la couverture insuffisante, la précision limitée pour les adresses informelles, la dépendance technologique et les coûts élevés. La mise en place d'un géocodeur interne est donc apparue comme une nécessité stratégique, permettant à l'entreprise de :

— maîtriser ses données de localisation,
— adapter l'outil aux réalités du Koweït et de la Tunisie,
— réduire les coûts liés aux API externes,
— offrir un service plus fiable et sur-mesure à ses clients.

1.3.4 Solution proposée

Pour surmonter les limites identifiées lors de l'étude de l'existant, Armada Delivery a conçu un **géocodeur interne**, spécifiquement développé pour la plateforme **Armada Ettijaht**. Ce système vise à transformer les adresses textuelles saisies par les clients en coordonnées géographiques fiables (latitude et longitude), afin d'améliorer la précision des calculs de distances et d'itinéraires.

Contrairement aux API externes, ce géocodeur prend en compte les particularités locales du marché koweïtien, où de nombreuses adresses ne suivent pas de format standardisé ou ne sont pas référencées dans les bases mondiales. Il intègre des données enrichies et mises à jour en continu, ce qui permet d'assurer une meilleure couverture et d'éviter les erreurs de localisation.

Les principaux apports de cette solution sont :

- Une **précision accrue** dans l'estimation des distances et des temps de trajet.
- Une **optimisation des itinéraires** pour les chauffeurs, réduisant les coûts logistiques et les retards.
- Une **réduction des erreurs de géocodage**, notamment pour les zones peu couvertes par les services externes.
- Une **amélioration notable de l'expérience client**, grâce à des livraisons plus rapides et plus fiables.
- Une **autonomie stratégique**, en limitant la dépendance aux solutions tierces et en offrant la possibilité d'adapter le système à d'autres marchés régionaux.

Ainsi, le développement de ce géocodeur interne représente une étape clé pour Armada Delivery, en renforçant son efficacité opérationnelle et en consolidant sa position dans le domaine de la logistique urbaine.

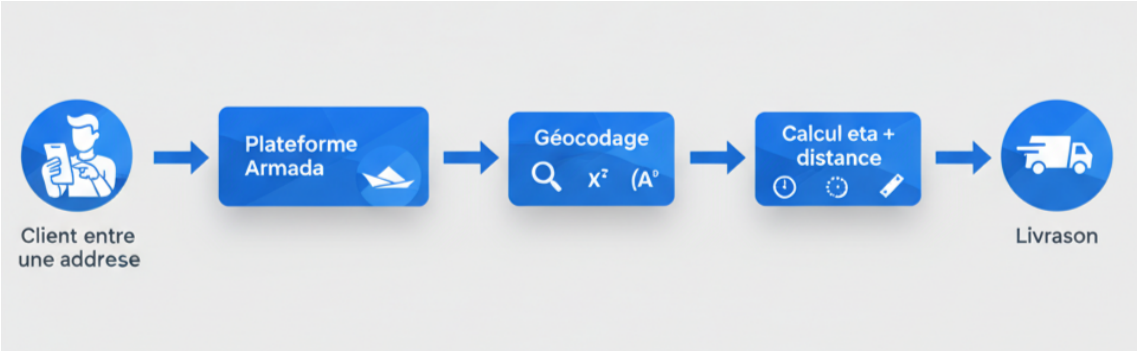


FIGURE 1.2 – Processus global de livraison + géocodage

1.4 Méthodologie de travail et planification

1.4.1 Introduction

Le projet de développement d'un **geocoder interne** pour la plateforme Armada Delivery Solutions nécessite la gestion à la fois de ressources techniques (données volumineuses d'adresses et de coordonnées) et de processus scientifiques rigoureux. Pour garantir l'efficacité et la qualité du projet, nous avons combiné deux approches :

— Une **méthodologie de gestion de projet Agile** pour le suivi organisationnel et la coordination de l'équipe.

— Une **méthodologie Data Science** basée sur CRISP-DM pour le traitement et la modélisation des données.

1.4.2 Méthodologie Scrum

La méthodologie **Scrum**, une implémentation concrète d'Agile, a été adoptée afin d'assurer une organisation flexible et efficace du projet, permettant à l'équipe de s'adapter rapidement aux changements et aux besoins spécifiques de la plateforme Armada Delivery Solutions. Elle a structuré le travail en sprints et favorisé la collaboration et la communication entre les membres de l'équipe.

— **Rôles Scrum** :

— **Product Owner** : responsable de la définition des priorités, de la gestion du Product Backlog et de la communication avec les

parties prenantes.
  - **Scrum Master** : facilite le processus Scrum, supprime les obstacles et veille au respect des bonnes pratiques.
  - **Équipe de développement** : réalise les tâches et livre les incréments fonctionnels du produit.
- **Product Backlog et Sprint Backlog** : le Product Backlog contient l'ensemble des fonctionnalités à développer, priorisées selon leur valeur pour le projet. Le Sprint Backlog est constitué des tâches choisies pour chaque sprint, définissant les objectifs à atteindre.
- **Sprint Planning** : au début de chaque sprint, l'équipe définit les objectifs et sélectionne les tâches du Product Backlog à réaliser. Chaque tâche est attribuée en fonction des compétences et de la charge de travail de chaque membre, permettant une planification claire et réaliste.
- **Daily Scrum** : réunions quotidiennes de 15 minutes au cours desquelles chaque membre partage ses progrès, les obstacles rencontrés et les actions prévues pour la journée. Cela favorise la transparence et permet à l'équipe de s'ajuster rapidement pour respecter les délais.
- **Sprints** : cycles de travail itératifs, généralement de 1 à 2 semaines, au terme desquels un incrément fonctionnel et testable est livré. Cette approche permet de générer des résultats concrets et d'obtenir des retours réguliers afin d'ajuster les développements suivants.
- **Sprint Review et Rétrospective** : à la fin de chaque sprint, la *Sprint Review* permet de présenter l'incrément réalisé, de vérifier sa conformité avec les objectifs et de recueillir les retours du Product Owner et des parties prenantes. La *Sprint Retrospective* analyse le processus de travail pour identifier les points forts, les difficultés rencontrées et proposer des améliorations pour les prochains sprints.
- **Bénéfices de Scrum** : l'utilisation de Scrum a permis une meilleure coordination de l'équipe, une communication plus fluide et une adaptation rapide aux changements. Elle a assuré une visibilité continue sur l'avancement du projet, tout en garantissant la qualité des li-

vrables grâce à des incréments testés et validés régulièrement.

Ainsi, l'adoption de la méthodologie Scrum a combiné rigueur et flexibilité, garantissant que le projet progresse de manière structurée tout en restant adaptable aux besoins évolutifs de l'entreprise et aux contraintes techniques spécifiques au développement du geocoder interne.

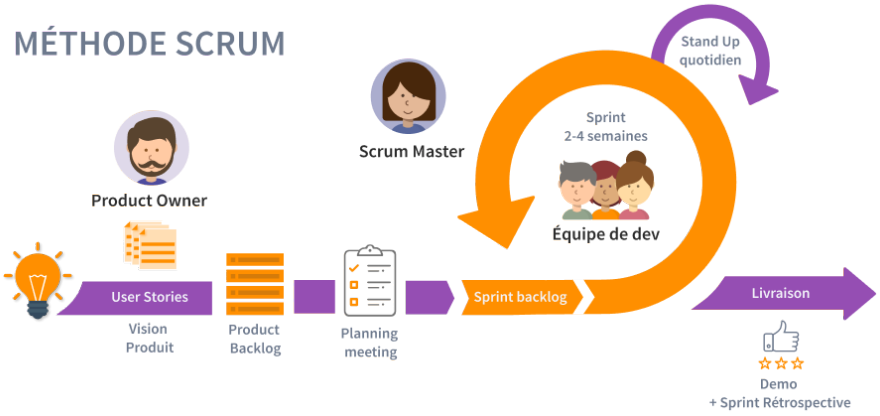


FIGURE 1.3 – Phases de la méthodologie Scrum

1.4.3 Méthodologie Data Science (CRISP-DM)

Le projet étant basé sur la science des données, la méthodologie **CRISP-DM** (Cross-Industry Standard Process for Data Mining) a été choisie pour structurer le développement du geocoder interne. Cette approche permet de suivre un processus itératif et rigoureux, garantissant la qualité et la fiabilité des résultats. Elle se déroule en six phases principales .

1. **Compréhension du métier** : cette première étape a consisté à analyser les besoins d'Armada Delivery, à identifier les objectifs précis du geocoder et à définir les contraintes liées au marché koweïtien. L'accent a été mis sur la précision des adresses, la couverture complète du territoire et l'intégration fluide avec la plateforme existante.
2. **Compréhension des données** : cette phase a impliqué la collecte et l'exploration des données disponibles, notamment les adresses clients, restaurants et commerces. Une analyse détaillée a été réalisée pour évaluer la qualité des données, identifier les incohérences,

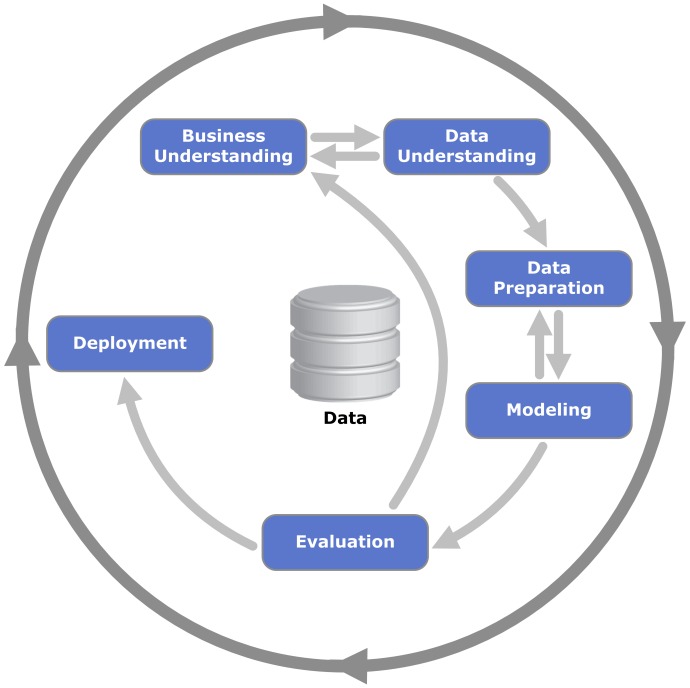


FIGURE 1.4 – Phases de la méthodologie CRISP-DM

les doublons et les adresses manquantes. Des statistiques descriptives ont été générées pour mieux comprendre la distribution géographique des adresses et les zones nécessitant un enrichissement.

3. **Préparation des données** : les données brutes ont été nettoyées et normalisées afin d'éliminer les erreurs et d'uniformiser le format des adresses. Des règles ont été appliquées pour corriger les fautes de frappe, standardiser les noms de rues et gérer les adresses manquantes ou approximatives. Cette étape a également inclus la structuration des données sous un format exploitable pour le geocoder et l'intégration éventuelle de sources externes de référence.
4. **Modélisation** : un geocoder interne a été développé et intégré à la plateforme Armada. Cette phase a consisté à transformer les adresses textuelles en coordonnées géographiques exploitables, en s'assurant d'une couverture complète et d'une précision optimale. Des tests ont été effectués pour évaluer la pertinence des résultats et ajuster les règles et méthodes de traitement afin de maximiser la fiabilité du système.
5. **Évaluation** : les résultats du geocoder ont été comparés à des

adresses réelles et des données de référence pour vérifier leur exactitude. Les erreurs ont été analysées pour identifier les causes et améliorer le traitement des cas particuliers. Cette phase a permis de valider la performance du modèle avant son déploiement.

6. **Déploiement** : le geocoder interne a été intégré dans la plateforme Armada, remplaçant progressivement l'API externe utilisée précédemment. Cette intégration a permis un traitement autonome des adresses, une meilleure maîtrise de la qualité des données et une amélioration de la précision des estimations de livraison, contribuant ainsi à l'optimisation des itinéraires et à une meilleure expérience client.

Cette méthodologie a assuré une progression structurée et méthodique du projet, en garantissant que chaque étape est validée avant de passer à la suivante, tout en permettant des ajustements itératifs en fonction des observations et des retours obtenus.

1.5 Conclusion

Ce chapitre a présenté le contexte général du projet et l'importance du géocodage pour Armada Delivery Solutions. Face aux limites des solutions existantes, la conception d'un **geocoder interne** s'impose pour améliorer la précision des itinéraires et l'expérience client. La méthodologie adoptée, combinant **CRISP-DM** et **Scrum**, assure à la fois rigueur scientifique et flexibilité dans la conduite du projet.

Chapitre 2

Compréhension des métiers

2.1 Introduction

La phase de **compréhension des métiers** (*Business Understanding*), première étape du processus **CRISP-DM**, vise à aligner le projet de *data science* sur les besoins réels de l'entreprise.

Pour **Armada Delivery Solutions**, spécialisée dans la livraison du dernier kilomètre au Koweït, cela implique de répondre aux enjeux de compétitivité, d'intégrer les contraintes locales et d'assurer la viabilité économique du projet.

2.2 Le géocodage et son importance dans la logistique

2.2.1 Définition du géocodage

Le **géocodage** (*geocoding*) est le processus qui consiste à transformer une adresse textuelle (par exemple : *"Block 3, Salmiya, près du centre commercial"*) en coordonnées géographiques précises (latitude et longitude). Ces coordonnées sont ensuite exploitables par des systèmes d'information

géographique (*Geographic Information Systems, GIS*) ou des applications de navigation.

On distingue deux formes principales de géocodage :

— **Forward geocoding** : conversion d'une adresse textuelle en coordonnées GPS. C'est le cas le plus utilisé dans les activités de livraison et de logistique.

— **Reverse geocoding** : opération inverse, consistant à convertir des coordonnées GPS en une adresse lisible par un utilisateur. Utile pour tracer les trajets effectués ou pour vérifier la localisation d'un point.

Dans le contexte d'Armada Delivery Solutions, c'est principalement le *forward geocoding* qui est mobilisé, car il permet de transformer les informations fournies par les clients en emplacements exploitables par les livreurs.

2.2.2 Utilité du géocodage dans la livraison du dernier kilomètre

La livraison du **dernier kilomètre** (*last-mile delivery*), qui correspond au transport du colis depuis un centre logistique jusqu'au client final, est souvent considérée comme la partie la plus complexe et la plus coûteuse de la chaîne logistique. Selon plusieurs études, elle peut représenter jusqu'à **40% du coût total de livraison**.

Un *geocoding* fiable apporte plusieurs bénéfices majeurs :

— **Réduction des erreurs de localisation** : des adresses ambiguës comme *"près du café"* ou *"derrière l'école"* deviennent des coordonnées précises, ce qui diminue le taux d'échec de livraison.

— **Optimisation des itinéraires** (*route optimization*) : la conversion systématique des adresses en coordonnées GPS permet d'appliquer des algorithmes avancés de planification de tournées.

— **Amélioration de l'expérience client** (*customer experience*) : des livraisons plus rapides et plus fiables augmentent la satisfaction et la fidélité des clients, facteur clé dans un marché concurrentiel.

— **Réduction des coûts opérationnels** : gain de temps pour les livreurs, diminution de la consommation de carburant et meilleure gestion de la flotte de véhicules.

Ainsi, le *geocoding* ne se limite pas à une fonction technique : il constitue un véritable levier de performance opérationnelle et stratégique.

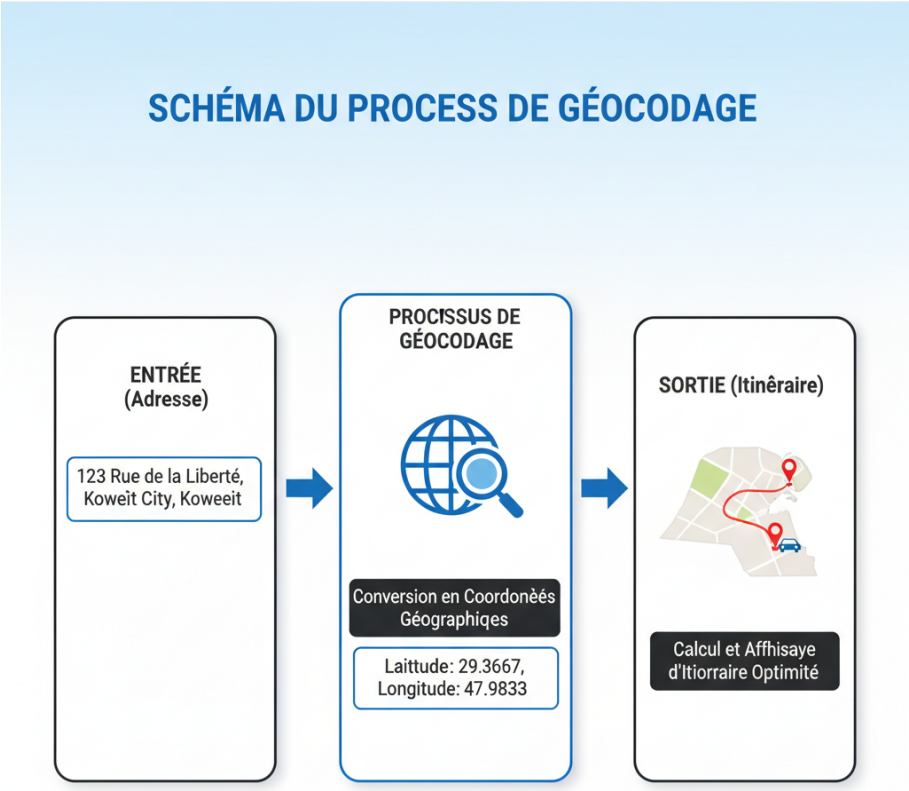


FIGURE 2.1 – Un schéma du processus de géocodage

2.2.3 Spécificités et défis au Koweït

Le contexte koweïtien illustre particulièrement bien l'importance d'un **géocodage adapté** :

— **Non-standardisation des adresses** : absence de système d'adressage uniforme, utilisation fréquente de descriptions approximatives.

— **Usage de points de repère** (*landmarks-based addressing*) : les clients décrivent souvent leur localisation par rapport à des lieux connus (*"en face de Starbucks"*).

— **Variations linguistiques et orthographiques** : les noms de quartiers et de rues peuvent être écrits en arabe ou en anglais, avec des transcriptions multiples (ex. : *Salmiya*, *Salmyia*,).

Ces spécificités limitent l'efficacité des API externes (Google Maps, HERE), qui ne sont pas optimisées pour les réalités locales. Un *internal geocoder* devient alors indispensable pour Armada Delivery Solutions.

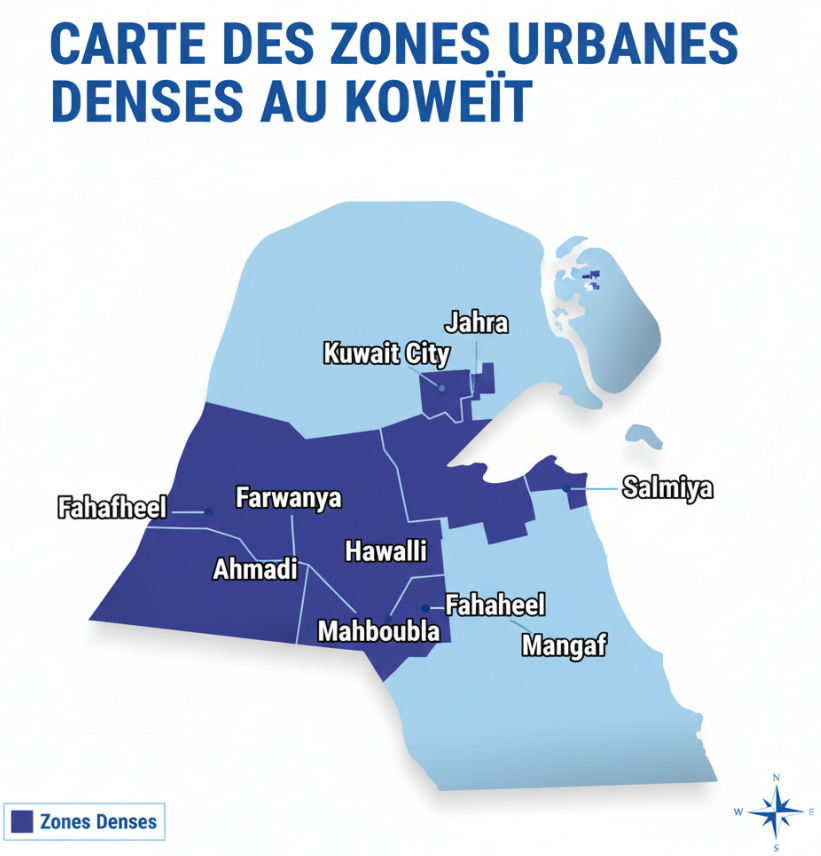


FIGURE 2.2 – Carte du Koweït mettant en évidence les zones urbaines denses (Salmiya, Hawalli, Farwaniya, etc.) où les problèmes d'adressage et de livraison sont particulièrement critiques.

2.2.4 Enjeux stratégiques du géocodage

Le géocodage dépasse le cadre technique et devient un véritable **avantage compétitif** :

— **Compétitivité** : un service de livraison plus rapide et précis permet à Armada de se démarquer face aux concurrents locaux et interna-

tionaux.

— **Économie de coûts** : réduction des frais liés aux API externes, qui deviennent coûteux à grande échelle, et optimisation interne des opérations.
— **Scalabilité** : un système interne peut être adapté à d'autres pays de la région MENA confrontés à des problématiques similaires.

2.3 Détermination des objectifs métiers

Les objectifs métiers traduisent les priorités stratégiques d'Armada Delivery Solutions face aux défis spécifiques du marché koweïtien :

— **Améliorer la précision du géocodage** : transformer des adresses ambiguës en coordonnées GPS fiables pour réduire les échecs de livraison.
— **Optimiser les opérations logistiques** : planifier des itinéraires plus courts et plus efficaces dans des zones urbaines complexes.
— **Améliorer l'expérience client** : offrir un service rapide et sans erreurs, facteur clé de différenciation.
— **Réduire la dépendance aux services externes** : éviter les limitations et les coûts récurrents liés aux API externes.
— **Faciliter l'expansion régionale** : développer une solution flexible et exportable dans d'autres pays.

2.4 Évaluation de la situation actuelle

Cette étape consiste à analyser l'environnement interne et externe de l'entreprise :

— **Ressources humaines** : équipe interne compétente en logistique et développement logiciel, nécessitant un renforcement en *data science*.
— **Ressources organisationnelles** : infrastructure logistique existante (plateforme Armada Ettijaht), mais dépendante d'API externes.

— **Contraintes métier** : forte densité urbaine, adresses non uniformisées, bilinguisme arabe/anglais.
— **Risques** : retards ou échecs de livraison, résistance au changement des livreurs, pression concurrentielle.
— **Analyse coût-bénéfice** : investissement initial important, mais bénéfices à long terme en termes de réduction des coûts et de fiabilité.

2.5 Détermination des objectifs data science

Les objectifs de *data science* traduisent les besoins métiers en tâches analytiques concrètes :

— **Cartographier les formats d'adresses** : identifier et analyser les variations linguistiques et structurelles.
— **Développer un géocodeur interne** : créer un pipeline capable de gérer les adresses ambiguës et multilingues.
— **Assurer la scalabilité** : concevoir un système extensible pour traiter des volumes croissants et s'adapter à d'autres marchés.
— **Mesurer la performance** : définir des métriques précises (taux de succès du géocodage, temps de livraison, satisfaction client).

2.6 Élaboration du plan de projet

Le plan de projet définit les grandes étapes et les ressources nécessaires :

— **Étapes clés** : collecte des besoins, définition des critères de succès, conception du pipeline de *geocoding*, déploiement progressif.
— **Délais** : une phase initiale de 2 à 3 semaines pour la collecte et la validation des besoins.
— **Ressources** : budget, équipe projet (logistique, informatique, *data science*), accès aux données internes.
— **Critères de succès** : réduction mesurable des erreurs de livraison, satisfaction client accrue, diminution des coûts liés aux API externes.

2.7 Outils et technologies utilisés

Le projet a mobilisé plusieurs outils et technologies, répartis entre environnements de développement, bibliothèques de traitement de données, bases de données et frameworks de modélisation.

2.7.1 Environnements de développement

— **Python 3.10** : langage principal pour l'ensemble des étapes (préparation des données, modélisation, évaluation).



FIGURE 2.3 – Logos de Python

2.7.2 Bibliothèques de traitement et visualisation

— **Pandas** : manipulation des données tabulaires, nettoyage et exploration.
— **NumPy** : calcul numérique et manipulation de matrices.
— **Matplotlib & Seaborn** : création de graphiques et visualisations statistiques.

2.7.3 Bibliothèques de modélisation et d'évaluation

— **Scikit-learn** : prétraitement, extraction de caractéristiques, métriques d'évaluation.
— **XGBoost** : algorithme de gradient boosting utilisé comme modèle principal.
— **FAISS (Facebook AI Similarity Search)** : librairie pour la recherche rapide de plus proches voisins en haute dimension, utilisée dans l'approche hybride.

2.7.4 Bases de données et stockage

— **MongoDB** : base de données NoSQL utilisée pour stocker des adresses, des points géographiques et des résultats de prédiction. Sa structure orientée documents (JSON-like) est adaptée à la nature non structurée des adresses textuelles.



FIGURE 2.4 – Logo de MongoDB utilisé pour le stockage

2.7.5 Traitement du langage et embeddings

— **SentenceTransformers (MiniLM-L6-v2)** : génération d'embeddings sémantiques pour représenter les adresses textuelles dans un espace vectoriel.

— **Scikit-learn TF-IDF Vectorizer** : extraction de caractéristiques textuelles basées sur la fréquence des termes.

2.7.6 Gestion de projet et collaboration

— **Git** : contrôle de version et collaboration.

— **Google Colab** : exécution de notebooks en environnement cloud avec ressources GPU.



FIGURE 2.5 – Logos des outils de gestion de projet et collaboration

2.8 Conclusion

Cette phase de **Business Understanding** a permis de définir les objectifs stratégiques d'Armada Delivery Solutions et de montrer que le géocodage constitue une brique essentielle pour améliorer la précision, réduire les coûts et renforcer la compétitivité. En tenant compte des contraintes locales du Koweït et des ambitions régionales de l'entreprise, elle garantit que les prochaines étapes du processus CRISP-DM resteront alignées sur les priorités métier et à fort impact opérationnel.

Chapitre 3

Compréhension des données

3.1 Introduction

La phase de compréhension des données, deuxième étape du processus CRISP-DM, consiste à analyser les données disponibles afin d'évaluer leur qualité, leur structure et leur adéquation avec les objectifs métiers définis précédemment. Dans le cadre de ce projet, l'objectif est de développer un *geocoder interne* pour **Armada Delivery Solutions**, capable de normaliser et géolocaliser les adresses collectées lors des livraisons au Koweït.

Le présent chapitre s'appuie sur le *notebook Jupyter* qui documente la connexion à la base MongoDB, l'extraction des adresses et les premières analyses descriptives.

3.2 Collecte initiale des données

3.2.1 Source et extraction

Les données proviennent de la base **MongoDB**, collection `addresses`.

— **Critères de sélection** : uniquement les enregistrements du pays « Kuwait » et non supprimés (`deleted = false`).

— **Volume extrait** : 136 750 enregistrements.

— **Structure des documents** : chaque enregistrement est un document JSON contenant plusieurs champs relatifs à l'adresse.

3.2.2 Exemple de document

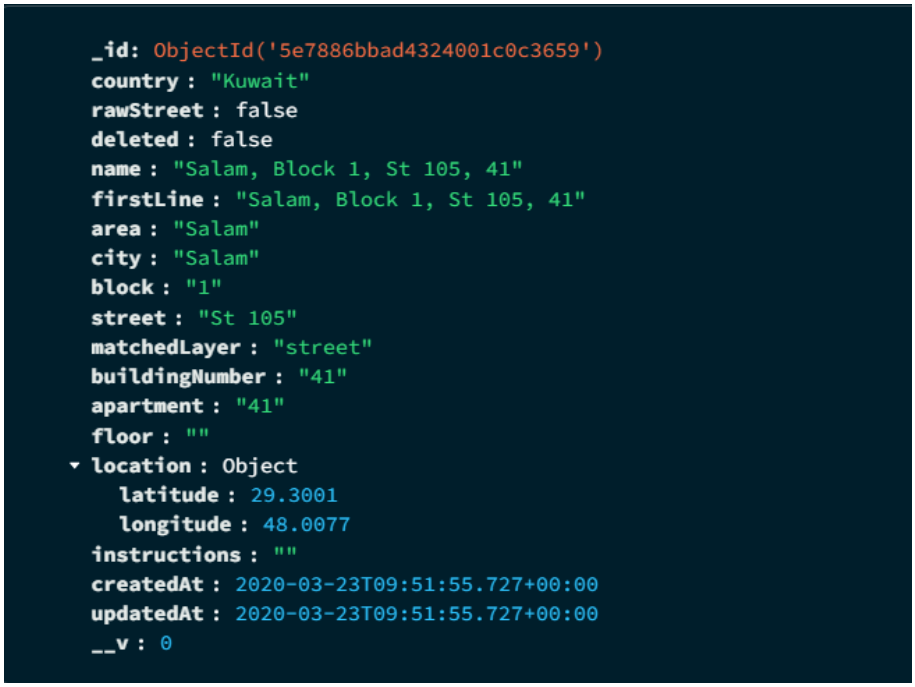


FIGURE 3.1 – Un exemple de document extrait

Cet exemple illustre la richesse des informations disponibles : **zone**, **bloc**, **rue**, **numéro de bâtiment**, **appartement**, ainsi que les coordonnées géographiques (**latitude** et **longitude**).

Pour illustrer l'hétérogénéité :

— Exemple d'adresse **complète** : « Salmiya, Block 3, Street 12, Building 45, Apt 8, latitude 29.33, longitude 47.99 ».

— Exemple d'adresse **incomplète** : « Hawalli » (zone seule, sans détails ni coordonnées).

3.3 Description des données

3.3.1 Champs principaux

Les champs les plus importants pour la tâche de géocodage sont :

— `area` : zone (ex. Salam, Salmiya, Sabah Al-Salem).
— `city` : généralement identique à la zone, mais peut varier.
— `block`, `street`, `buildingNumber`, `apartment` : niveau de détail de l'adresse.
— `latitude`, `longitude` : coordonnées géographiques.
— `instructions` : texte libre (repères, indications locales).

3.3.2 Résumé numérique des champs

Un premier aperçu statistique des champs principaux est donné dans le tableau 3.1.

Champ	**Nombre**	**Valeurs uniques**	**Valeur la plus fréquente**	**Fréquence**
Area	136750	159	Sabah Al-Salem	5609
Block	136750	37	1	26529
Street	136750	12038	St 1	7779

TABLE 3.1 – Résumé numérique des champs principaux

3.3.3 Distribution des blocs et rues

Les blocs sont représentés par seulement 37 valeurs distinctes, les plus fréquents étant listés ci-dessous :

— Bloc 1 : 26 529 occurrences.
— Bloc 2 : 21 769 occurrences.
— Bloc 3 : 19 657 occurrences.
— Bloc 4 : 16 462 occurrences.
— Bloc 5 : 11 922 occurrences.

Concernant les rues, on compte 12 038 valeurs distinctes. Les plus fréquentes sont :

— St 1 : 7 779 occurrences.
— St 2 : 4 219 occurrences.
— St 3 : 3 657 occurrences.

— St 4 : 3 195 occurrences.
— St 5 : 3 021 occurrences.

3.3.4 Couverture géographique

— **Zones uniques identifiées** : 159.
— **Répartition** : couvre les six gouvernorats du Koweït.
— **Distribution par gouvernorat** :
  — Hawalli : 21 948 adresses.
  — Capital : 10 813 adresses.
  — Mubarak Al-Kabeer : 8 570 adresses.
  — Ahmadi : 8 248 adresses.
  — Farwaniya : 6 336 adresses.
  — Jahra : 2 865 adresses.
  — Unknown : 6 adresses.
— **Langues** : arabe, anglais, ou mélange (ex. « Salmiya » et).

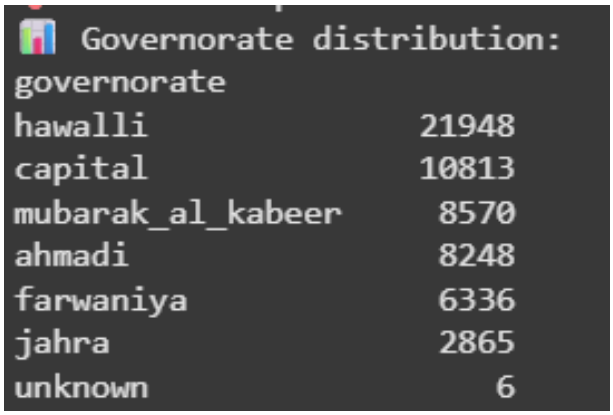


FIGURE 3.2 – Distribution par gouvernorat

3.4 Exploration des données

3.4.1 Zones les plus fréquentes

Certaines zones apparaissent beaucoup plus souvent que d'autres :
— Sabah Al-Salem : 5 609 enregistrements.
— Abdullah Mubarak Al-Sabah : 4 977 enregistrements.

— Salmiya : 4 483 enregistrements.

```
area: 159 unique values
area
Sabah Al-Salem                5609
Abdullah Mubarak Al-Sabah     4977
Salmiya                       4483
Salwa                         4217
Jabriya                       3930
Mishrif                       3757
Zahra                         3665
Bayan                         3319
Qortuba                       3294
Surra                         3121
Name: count, dtype: int64
```

FIGURE 3.3 – Top 10 des zones les plus fréquentes

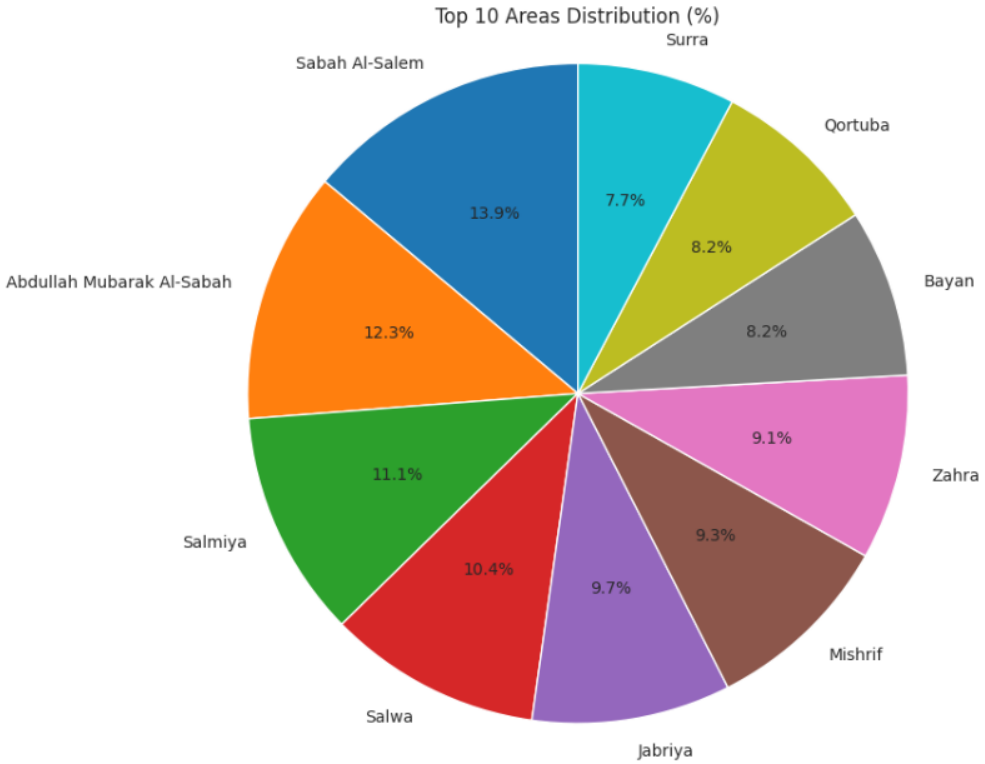


FIGURE 3.4 – Top 10 des zones les plus fréquentes(%)

À l'inverse, certaines zones sont très peu représentées (parfois une seule adresse), comme « Rawdatain ». Ces zones rares constituent des cas particuliers à surveiller.

3.4.2 Anomalies observées

— **Variations d'orthographe** : « Salmiya » vs « Salmiyah ».
— **Doublons potentiels** : « Shuwaikh Industrial » vs « Shuwaikh Industrial Area ».
— **Langues mixtes** : certaines zones existent en arabe et en anglais (« Hawalli » vs « »).

3.5 Qualité des données

L'évaluation de la qualité des données repose sur les explorations effectuées dans le *notebook Jupyter*.

3.5.1 Complétude

— Tous les enregistrements possèdent un champ `area`.
— Mais 68% des adresses n'ont pas de `street` renseignée.
— 75% des adresses n'ont pas de `buildingNumber`.
— Environ 20% des adresses n'ont pas de coordonnées GPS (`latitude`, `longitude`).

3.5.2 Cohérence

— Doublons et variations linguistiques pour une même zone.
— Différences de granularité : certaines adresses sont très détaillées (bloc, rue, numéro), d'autres se limitent à la zone.

3.5.3 Pertinence

— Les données couvrent l'ensemble des zones utiles aux opérations d'Armada.
— Leur hétérogénéité rend nécessaire une étape de **nettoyage et de normalisation**.

3.6 Conclusion

La phase de **compréhension des données** met en évidence la richesse des informations collectées, mais aussi leurs limites : hétérogénéité des formats, variations linguistiques, champs manquants et coordonnées GPS incomplètes. Ces constats soulignent la nécessité d'une préparation rigoureuse des données afin d'obtenir un jeu exploitable et fiable pour la modélisation.

Chapitre 4

Data Preparation

4.1 Introduction

La phase de **Data preparation** constitue une étape fondamentale du processus CRISP-DM. Elle vise à transformer les données brutes issues de MongoDB en un *dataset* propre, cohérent et enrichi, prêt à être exploité par les algorithmes de Machine Learning.

Dans le cadre de ce projet, cette étape revêt une importance particulière car les adresses collectées au Koweït sont hétérogènes, parfois incomplètes, multilingues (arabe/anglais), et souvent dépourvues de coordonnées géographiques fiables. Un travail rigoureux de préparation permet donc d'obtenir une représentation standardisée et exploitable, condition préalable indispensable au développement d'un **geocoder interne** efficace pour Armada Delivery Solutions.

Les principales opérations effectuées sont les suivantes :

— **Data cleaning** et gestion des valeurs manquantes.
— **Normalisation** des formats textuels et numériques.
— **Équilibrage spatial** et calcul de poids d'échantillonnage.
— **Feature engineering** : création de variables numériques, géographiques, textuelles et vectorielles.
— **Construction du dataset final** et sauvegarde des statistiques.

4.2 Data Cleaning et gestion des valeurs manquantes

Le **data cleaning** regroupe les méthodes permettant de corriger, transformer ou supprimer les données incorrectes, incohérentes ou manquantes. Une telle étape est essentielle car un modèle d'apprentissage supervisé s'appuie sur la qualité des données fournies : toute incohérence ou bruit dans les données peut compromettre la précision des prédictions.

4.2.1 Taux de complétude des champs

Un premier diagnostic a été réalisé pour mesurer le **taux de complétude** des principaux champs (tableau 4.1).

Champ	**Taux de complétude**	**Observation**
Area	100%	Toujours présent
Block	45%	Fréquent mais incomplet
Street	32%	Majoritairement manquant
BuildingNumber	25%	Rarement renseigné
Apartment	12%	Très incomplet
Latitude / Longitude	80%	Coordonnées partiellement disponibles

TABLE 4.1 – Taux de complétude des champs principaux

L'analyse met en évidence la nécessité de concevoir des stratégies adaptées : les champs systématiquement renseignés (ex. `area`) peuvent être exploités comme variables centrales, tandis que les champs très incomplets (ex. `apartment`) nécessitent la création de variables indicatrices de présence/absence.

4.2.2 Normalisation des champs textuels

Les champs textuels (`area`, `block`, `street`) comportent de nombreuses variations orthographiques, doublons et formes multilingues.

Définition : La *normalisation textuelle* désigne l'ensemble des transformations appliquées aux chaînes de caractères afin d'uniformiser leur représentation.

Opérations appliquées :

— Conversion en minuscules pour éliminer la distinction artificielle entre majuscules et minuscules.

— Suppression des accents, espaces multiples et caractères spéciaux pour réduire le bruit.

— Standardisation des abréviations (`St`, `Street`, `Ave`, etc.).

Une telle normalisation réduit le risque de traiter comme distincts deux enregistrements qui décrivent en réalité la même entité géographique.

4.2.3 Nettoyage des numéros de bâtiment

Le champ `buildingNumber` contient souvent des combinaisons alphanumériques (« 45A », « Bldg 12B »). Deux variables dérivées ont été créées :

— `building_num` : partie numérique, utile pour les comparaisons quantitatives.

— `building_text` : partie textuelle, préservant les informations fines liées aux suffixes.

Une telle décomposition rend les données plus flexibles : elle permet d'exploiter les numéros comme valeurs continues tout en conservant la granularité apportée par les suffixes.

4.2.4 Création de variables indicatrices

Des **binary flags** ont été introduits afin d'indiquer la présence ou l'absence de certaines informations (`has_building`, `has_block`, `has_apartment`, `has_floor`).

L'existence même d'une information peut être révélatrice de la précision d'une adresse : une entrée contenant un numéro d'appartement est généralement plus localisée qu'une adresse limitée au quartier.

4.2.5 Encodage spatial avec Geohash

Le **geohash** est un système d'encodage qui convertit une paire `(latitude, longitude)` en une chaîne alphanumérique hiérarchique. Ce type d'encodage facilite la comparaison et le regroupement d'adresses proches. En introduisant cette variable, on enrichit les données d'une représentation spatiale compacte, adaptée aux modèles qui exploitent mal les coordonnées brutes.

4.3 Équilibrage spatial et pondération

Les adresses ne sont pas réparties uniformément sur le territoire : certaines zones urbaines concentrent la majorité des points tandis que d'autres sont sous-représentées. Un tel déséquilibre introduit un biais car le modèle, exposé principalement à des zones denses, tend à négliger les zones périphériques.

4.3.1 Kernel Density Estimation (KDE)

La **KDE** est une méthode statistique non paramétrique permettant d'estimer la densité de probabilité d'une variable aléatoire. Dans ce projet, elle est appliquée sur les coordonnées GPS pour évaluer la densité locale d'adresses. Chaque adresse est ainsi associée à une estimation de la concentration d'enregistrements autour d'elle.

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right)$$

4.3.2 Définition des poids d'échantillonnage

Les poids attribués aux adresses sont proportionnels à l'inverse de leur densité locale :

$$w_i = \frac{1}{\text{densité}(lat_i, lon_i)}$$

Les adresses situées dans des zones denses se voient donc attribuer un poids réduit, tandis que celles issues de zones moins représentées acquièrent

un poids renforcé. La normalisation des poids dans l'intervalle $[0.5, 2.0]$ permet de contenir les écarts excessifs.

4.3.3 Ajustement par gouvernorat

Un ajustement complémentaire a été réalisé par gouvernorat afin de compenser les déséquilibres structurels liés aux différences de population et de couverture entre régions. Ainsi, l'échantillon final reflète mieux la diversité territoriale du pays.

```
Example weights per governorate:
hawalli: 0.5000
capital: 0.6000
mubarak_al_kabeer: 0.7000
ahmadi: 0.8003
farwaniya: 0.9000
jahra: 1.0001
```

FIGURE 4.1 – Distribution des poids d'échantillonnage (`sample_weight`)

4.4 Feature Engineering

Le **feature engineering** est le processus de transformation des données brutes en variables (*features*) significatives et adaptées à l'algorithme choisi. Un modèle supervisé ne peut apprendre que de ce qui lui est fourni ; d'où l'importance de créer des variables qui capturent les dimensions pertinentes du problème.

4.4.1 Features géographiques hiérarchiques

Pour chaque niveau géographique (country, governorate, area, city), des indicateurs statistiques ont été calculés :

— La moyenne des coordonnées (`lat_mean`, `lon_mean`) représente la localisation typique d'une zone.

— L'écart-type (`lat_std`, `lon_std`) mesure la dispersion spatiale, révélant si une zone est compacte ou étendue.

Ces variables résument des zones entières en des représentations numériques faciles à exploiter par les modèles.

$$lat_mean = \frac{1}{n}\sum_{i=1}^{n} lat_i, \quad lon_mean = \frac{1}{n}\sum_{i=1}^{n} lon_i$$

$$lat_std = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(lat_i - lat_mean)^2}, \quad lon_std = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(lon_i - lon_mean)^2}$$

4.4.2 Features numériques

Les numéros extraits (`building_num`, `block_num`) fournissent un degré de précision supplémentaire. Combinés aux indicateurs binaires (`has_building`, etc.), ils permettent d'appréhender la granularité de l'adresse fournie par l'utilisateur.

4.4.3 TF-IDF Features

Le **TF-IDF (Term Frequency - Inverse Document Frequency)** est une technique de vectorisation textuelle.

— La *fréquence* (TF) mesure combien de fois un terme apparaît dans un document.

— L'*inverse document frequency* (IDF) réduit l'importance des termes fréquents et peu discriminants.

Appliqué à des n-grams de caractères (de taille 2 à 6), le TF-IDF capture des motifs fréquents (« St », « Block », « Bldg »). Une limitation à 1024 dimensions permet de concilier richesse descriptive et efficacité computationnelle. Cette représentation rend les modèles sensibles aux régularités structurelles des adresses.

4.4.4 Sentence Embeddings

Les **embeddings** sont des représentations vectorielles continues obtenues par des modèles de langage. Ici, le modèle `paraphrase-MiniLM-L6-v2` a été utilisé pour projeter chaque adresse dans un espace dense de dimension 384.

Deux adresses proches sémantiquement, même si elles diffèrent dans la forme ou la langue, se trouvent représentées par des vecteurs voisins. Les embeddings complètent ainsi le TF-IDF en capturant les similarités de sens et non seulement de forme.

4.5 Construction du dataset final

L'ensemble des variables construites est fusionné dans une structure finale comprenant :

— La matrice des **features** `X`, combinant données numériques, géographiques, textuelles et vectorielles.

— Les labels `y`, correspondant aux coordonnées géographiques cibles.

— Les poids `sample_weight`, utilisés pour corriger les déséquilibres d'échantillonnage.

Un découpage en ensembles d'apprentissage (80%) et de test (20%) a été appliqué. Les variables numériques ont été standardisées à l'aide d'un **StandardScaler**, garantissant une distribution homogène et facilitant la convergence des modèles.

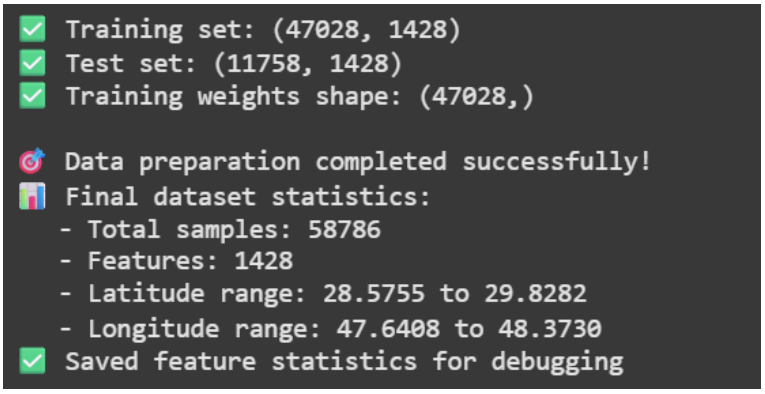


FIGURE 4.2 – Dataset final

4.6 Sauvegarde et reproductibilité

Afin d'assurer la reproductibilité et la pérennité du pipeline de préparation, plusieurs fichiers de configuration ont été sauvegardés :

— `geo_stats.pkl` : statistiques géographiques calculées.

— `feature_stats.json` : valeurs de référence (moyennes, écarts-types, min, max).
— `sample_weights.npy` : pondérations spatiales.

Ces éléments permettent de garantir que toute future utilisation du modèle reposera sur les mêmes règles de préparation.

4.7 Conclusion

La phase de **Data Preparation** a permis de transformer les données brutes en un jeu structuré, équilibré et exploitable. Grâce au nettoyage, à la gestion des valeurs manquantes, à l'équilibrage spatial et à la création de représentations textuelles (TF-IDF, embeddings), la qualité du dataset a été considérablement renforcée. Ces résultats offrent une base fiable pour la phase suivante de **modélisation**.

Chapitre 5

Modélisation et Évaluation

5.1 Introduction

La phase de **Modélisation et Évaluation**, cœur du processus *CRISP-DM*, consiste à concevoir et comparer des modèles de *machine learning* capables de convertir une adresse textuelle en coordonnées géographiques.

Dans le cas d'**Armada Delivery Solutions**, la qualité du géocodage est cruciale pour la livraison du dernier kilomètre. Les particularités des adresses koweïtiennes (multilinguisme, translittérations, repères locaux) justifient une approche combinant généralisation et précision locale.

5.2 Stratégie de modélisation

L'approche expérimentale adoptée combine :

— une stratégie **globale** fondée sur un modèle d'ensemble robuste (*Enhanced XGBoost*) capable d'apprendre des patterns larges dans les données multi-sources ;

— une stratégie **hybride** (*XGBoost + FAISS*) qui ajoute une couche de correction locale basée sur la recherche de voisins en espace d'*embeddings*, apportant précision dans les cas marginaux ou ambigus.

Les étapes concrètes mises en œuvre sont : sélection et standardisation des features, entraînement par validation croisée, optimisation d'hyperparamètres avec *early stopping*, construction d'index FAISS sur embeddings, et évaluation avec métriques statistiques, géographiques et métier.

5.3 Métriques d'évaluation détaillées

Pour évaluer la qualité des géocodages, nous utilisons :

— **RMSE** et R^2 pour la performance globale sur les coordonnées (utile mais insuffisant seul),

— **Distance moyenne / médiane / 95e percentile** (métriques géographiques directement exploitables par les opérations),

— **Taux de couverture métier** : pourcentages d'adresses à l'intérieur de cercles de rayon 20 m, 50 m, 100 m et 200 m — indicateurs cruciaux pour la planification de tournées et la satisfaction client.

Formellement, la distance géodésique (approximation haversine pour petites distances) entre la paire (lat_i, lon_i) et la prédiction $(\hat{lat}_i, \hat{lon}_i)$ est calculée pour obtenir la distribution d'erreurs.

5.4 Enhanced *XGBoost* Geocoder

5.4.1 Rappel théorique

XGBoost (Extreme Gradient Boosting) est une implémentation optimisée du *gradient boosting* sur arbres de décision. Le principe du boosting est d'agréger séquentiellement des *weak learners* (arbres peu profonds) afin de réduire les résidus des prédictions précédentes. À chaque itération t, l'algorithme cherche une fonction $h_t(x)$ qui approxime le gradient de la fonction de perte :

$$\hat{y}_t(x) = \hat{y}_{t-1}(x) + \eta \cdot h_t(x)$$

où η est le *learning rate*. XGBoost ajoute des termes de régularisation ($L1$, $L2$) et des optimisations mémoire/CPU qui le rendent particulièrement adapté aux gros jeux de données tabulaires.

5.4.2 Features utilisées

Le modèle exploite des **features hétérogènes** construites lors de la phase de Data Preparation :

- **Features géographiques** : `geohash`, `lat_mean`/`lon_mean` par zone, `lat_std`/`lon_std`, indicateurs de densité (KDE).
- **Features numériques** : `building_num`, `block_num`, flags binaires (`has_building`, `has_apartment`, ...).
- **Features textuelles (NLP)** : TF-IDF sur n-grams de caractères (2–6), limité à 1024 dimensions.
- **Embeddings sémantiques** : vecteurs de dimension 384 issus de `sentence-transformers/paraphrase-MiniLM-L6-v2`.

5.4.3 Justification du choix

XGBoost excelle sur les données tabulaires et permet d'intégrer facilement des variables issues du NLP (TF-IDF, embeddings). Il fournit des mesures d'importance de variables utiles pour l'interprétabilité (feature importance), et sa robustesse en fait un bon point de départ avant d'introduire des mécanismes de correction locale.

5.4.4 Procédure d'entraînement

1. Normalisation / standardisation des features numériques (`StandardScaler`).
2. Fusion des matrices TF-IDF et embeddings (sparse + dense).
3. Split `train/test` (80% / 20%) avec stratification spatiale via geohash pour préserver la distribution territoriale.
4. Recherche d'hyperparamètres par validation croisée (grid / random search) sur : `max_depth`, `learning_rate`, `n_estimators`, `subsample`, `colsample_bytree`.
5. Entraînement avec *early stopping* sur un jeu de validation.

5.4.5 Résultats empiriques

```
==================================================
TRAINING ENHANCED XGBOOST
==================================================
🚀 Training Enhanced XGBoost models...
   Using validation set for early stopping...
✅ XGBoost models trained successfully!

🎯 Enhanced XGBoost Results:
📊 R² Score: 0.9951
📍 RMSE: 0.005580
📏 Mean Distance Error: 462.97 m
📏 Median Distance Error: 368.20 m
📏 95th Percentile Error: 1128.89 m
🎯 within_20m: 0.19%
🎯 within_50m: 1.26%
🎯 within_100m: 5.13%
🎯 within_200m: 18.94%
🎯 within_500m: 70.90%
🎯 within_1000m: 93.49%
```

5.4.6 Analyse qualitative

Malgré un excellent R^2, la métrique réellement pertinente pour la livraison est la distance géographique absolue entre la prédiction et la vérité terrain. Les très faibles proportions d'adresses sous 50–100 m montrent qu'une solution purement globale manque de précision locale (confusions entre rues/blocks proches, erreurs de translittération non résolues uniquement par TF-IDF/embeddings).

5.5 Hybrid *XGBoost + FAISS* Geocoder

5.5.1 Composants et principes

L'approche hybride combine :

— une estimation globale $\hat{y}^{(G)}$ fournie par *XGBoost*,

— une correction locale basée sur la recherche des k plus proches voisins dans l'espace d'*embeddings* via *FAISS*, qui renvoie les coordonnées réelles des voisins $(y_j)_{j=1..k}$.

Techniquement :

1. Construire des *embeddings* (e_i) pour chaque adresse de la base de référence.
2. Indexer ces embeddings avec FAISS (ex. : IVF+PQ, HNSW ou Flat selon compromis vitesse/qualité).
3. Pour une adresse cible, obtenir son embedding e^* et interroger FAISS pour récupérer les k voisins les plus proches.
4. Combiner la prédiction globale $\hat{y}^{(G)}$ et les coordonnées des voisins (moyenne pondérée, régression locale, ou correction par translation) pour produire la prédiction finale $\hat{y}^{(H)}$.

5.5.2 Pourquoi FAISS ?

FAISS offre des structures d'indexation optimisées pour la recherche de similarité à grande échelle. Ses avantages :

— échelle : millions de vecteurs gérables en mémoire / disque,
— vitesse : latences réduites grâce aux quantifications et algorithmes d'index,
— flexibilité : choix d'index (Flat, IVF, HNSW, PQ) selon contrainte CPU/mémoire.

5.5.3 Résultats empiriques

```
==================================================
TRAINING HYBRID XGB + FAISS
==================================================
🔥 Training Hybrid XGBoost + FAISS model...
🚀 Training Enhanced XGBoost models...
   Using validation set for early stopping...
✅ XGBoost models trained successfully!
✅ FAISS indexes built with 42325 reference points

🎯 Hybrid XGB + FAISS Results:
📊 R² Score: 0.9989
📍 RMSE: 0.002645
📏 Mean Distance Error: 116.15 m
📏 Median Distance Error: 58.24 m
📏 95th Percentile Error: 403.73 m
🎯 within_20m: 32.16%
🎯 within_50m: 46.65%
🎯 within_100m: 64.14%
🎯 within_200m: 82.96%
🎯 within_500m: 97.05%
🎯 within_1000m: 99.53%
```

5.5.4 Interprétation

L'ajout de FAISS réduit drastiquement la queue de la distribution d'erreurs (valeurs extrêmes) et augmente fortement les taux de succès aux seuils métier critiques (20–200 m). Cette amélioration est particulièrement visible dans les zones urbaines denses où des adresses très proches sémantiquement correspondent à coordonnées distinctes.

5.6 Visualisations et interprétations

Les figures suivantes, produites et sauvegardées depuis le notebook, permettent de visualiser la distribution et la nature des erreurs de localisation. Elles complètent les résultats numériques (RMSE, distances moyenne/médiane, taux de précision) en apportant une compréhension plus fine du comportement des modèles.

5.6.1 Distribution des erreurs géographiques

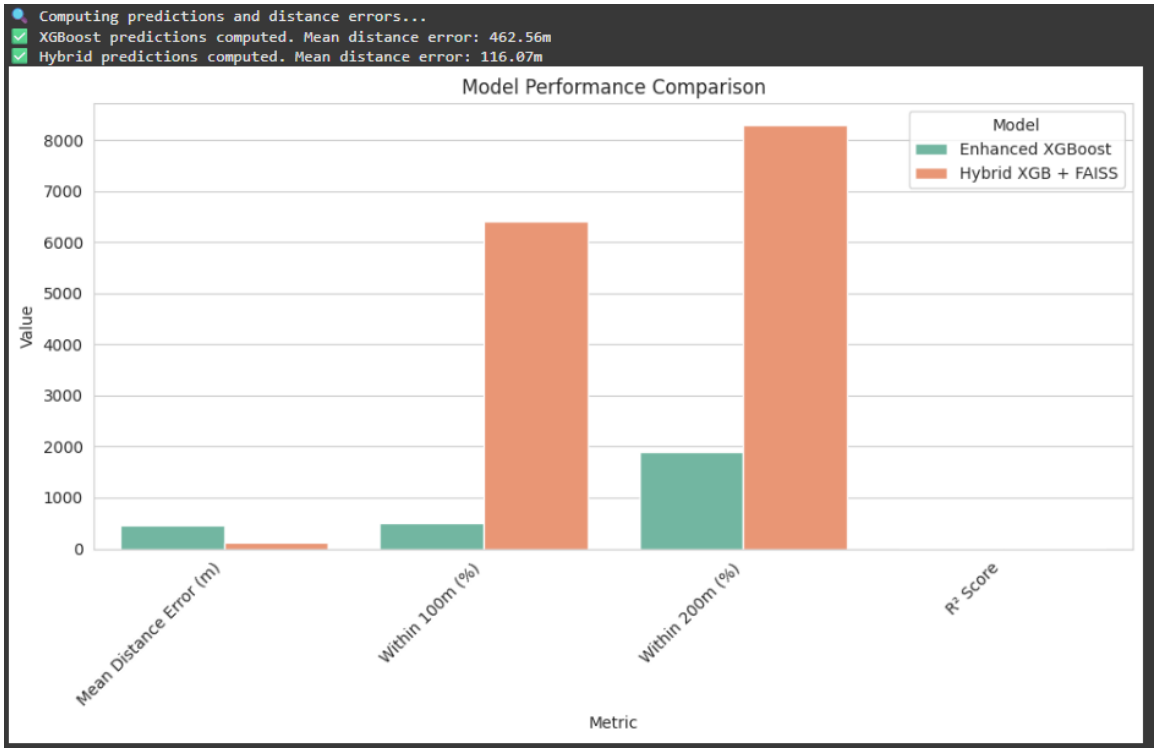


FIGURE 5.1 – Distribution des erreurs géographiques (histogramme) pour XGBoost et Hybrid XGBoost+FAISS.

Interprétation : L'histogramme montre une forte dispersion des erreurs pour le modèle **XGBoost seul**, avec une proportion importante de prédictions dépassant les 00 mètres. En revanche, l'approche **hybride XGBoost+FAISS** concentre la majorité de ses prédictions dans des intervalles beaucoup plus faibles (inférieurs à 200 mètres), ce qui confirme sa capacité à corriger localement les approximations du modèle global. Cette différence est particulièrement visible dans la réduction des *outliers*, qui sont beaucoup plus fréquents dans le modèle XGBoost pur.

5.6.2 Courbe cumulative des erreurs (CDF)

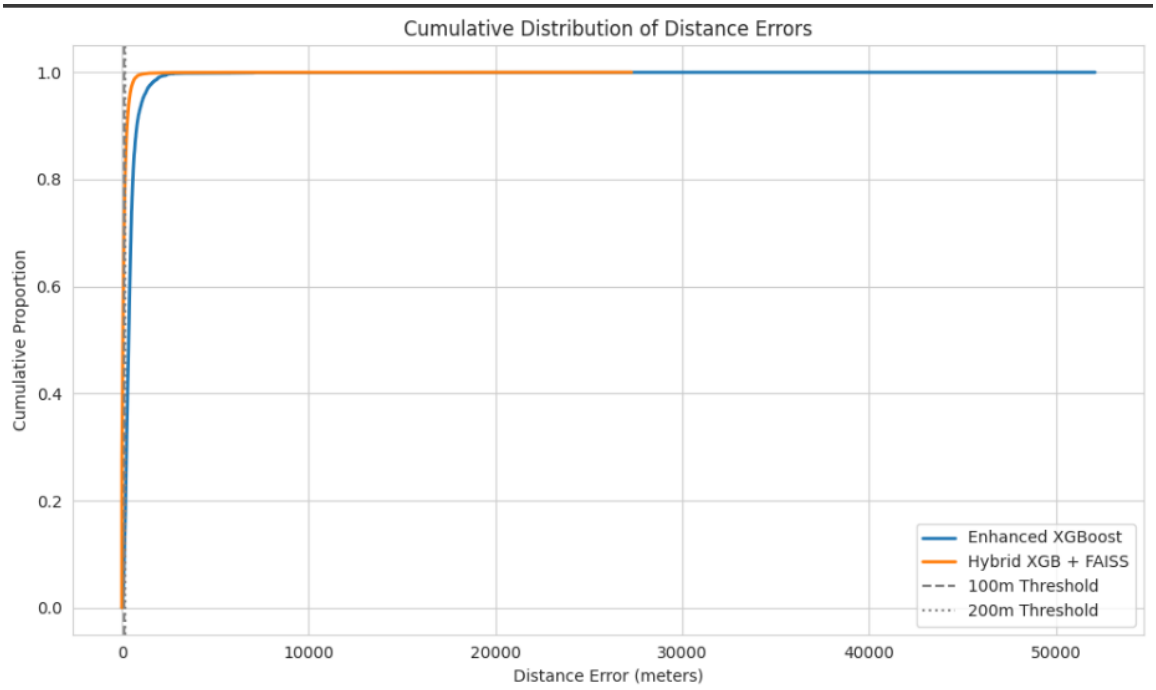


FIGURE 5.2 – Courbe cumulative (CDF) des erreurs de localisation — proportion d'adresses sous un rayon donné.

Interprétation : La CDF illustre la proportion d'adresses correctement localisées sous différents seuils de distance. On observe que le modèle **XGBoost seul** peine à dépasser 20% d'adresses sous 200 mètres, tandis que l'approche **hybride atteint plus de 80%**. L'écart est encore plus significatif pour les seuils bas (50 m et 100 m), directement liés à l'expérience des livreurs : l'hybride positionne près de la moitié des adresses sous 50 m, contre moins de 2% pour XGBoost. Cela confirme l'apport crucial de FAISS pour améliorer la précision locale, notamment dans les zones urbaines denses.

5.6.3 Visualisation géographique des prédictions

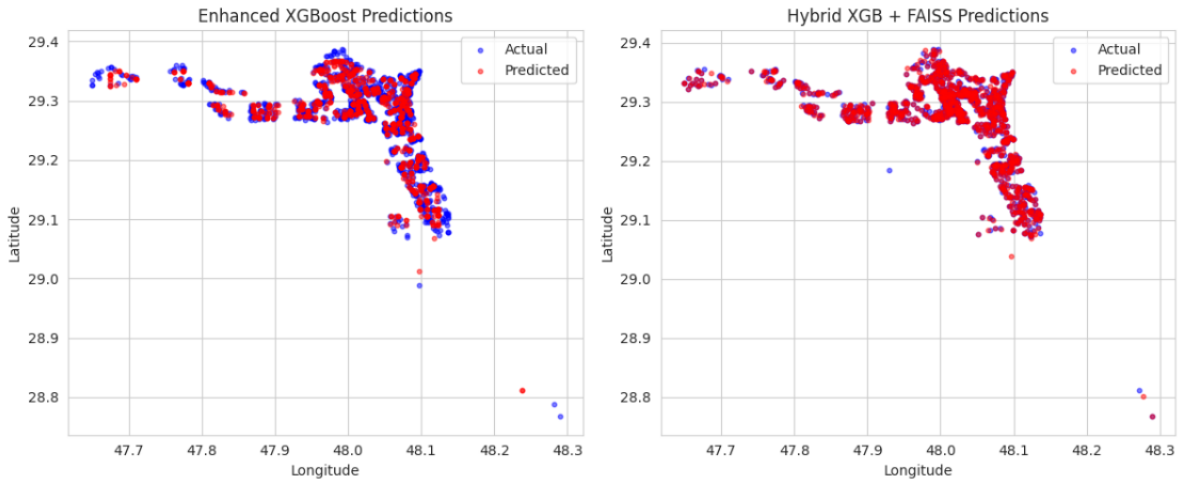


FIGURE 5.3 – Visualisation géographique : positions réelles (bleu) vs prédictions (rouge) pour un échantillon représentatif.

Interprétation : La carte géographique illustre la proximité (ou le décalage) entre les adresses réelles (points bleus) et les prédictions (points rouges). Pour XGBoost, les décalages sont fréquents, avec des points rouges souvent éloignés de plusieurs centaines de mètres. L'approche hybride montre une superposition beaucoup plus nette : les prédictions (rouge) coïncident visuellement avec les points bleus dans la majorité des cas. Ce résultat est particulièrement marquant dans des zones comme **Salmiya** ou **Hawalli**, où les adresses sont proches et ambiguës — l'hybride réussit à discriminer correctement des localisations très voisines.

5.6.4 Synthèse des visualisations

Les visualisations confirment les analyses chiffrées :

— L'**histogramme** montre une réduction nette des erreurs extrêmes.

— La **CDF** met en évidence la supériorité de l'hybride sur les seuils métiers critiques (20 m, 50 m, 100 m).

— La **carte** illustre concrètement l'amélioration de la précision, notamment dans les zones urbaines à forte densité d'adresses.

En résumé, l'ajout de FAISS permet non seulement d'améliorer les métriques numériques, mais aussi de rendre les prédictions exploitables opé-

rationnellement par les livreurs.

5.7 Conclusion

L'approche hybride **XGBoost + FAISS** s'est révélée la plus adaptée, combinant robustesse et précision locale pour améliorer significativement le géocodage au sein d'Armada Delivery Solutions.

Chapitre 6

Déploiement

6.1 Introduction

Après la phase de modélisation et d'évaluation (cf. Chapitre 5), la dernière étape du cycle *CRISP-DM* est le **déploiement**. Cette étape vise à rendre le modèle exploitable dans un environnement applicatif réel et accessible aux utilisateurs finaux.

Dans notre projet, le géocodeur développé a été intégré dans une application appelée **Ettijahet**, une plateforme destinée à la prédiction de la distance et de l'**ETA (Estimated Time of Arrival)** entre un point de collecte (*pickup*) et un point de dépôt (*drop*).

Initialement, Ettijahet fonctionnait uniquement à partir de coordonnées GPS (latitude et longitude) saisies par l'utilisateur. Avec le déploiement du géocodeur, une avancée majeure a été réalisée : l'utilisateur peut désormais saisir des **adresses textuelles naturelles** (par exemple : `"Salmiya, Block 3, Street 5"`) et le système se charge de les convertir automatiquement en coordonnées géographiques utilisables pour calculer ETA et distance.

6.2 Architecture fonctionnelle du déploiement

Le déploiement repose sur une intégration simple mais efficace, structurée autour d'une logique **API-first** :

- **API Géocodeur** : un service REST est exposé par la plateforme Armada.
  - **Entrée** : adresse en texte libre (pickup et drop).
  - **Pipeline interne** :
    1. prétraitement NLP (normalisation, embeddings),
    2. prédiction initiale avec XGBoost,
    3. correction locale avec FAISS,
    4. sortie en coordonnées GPS (latitude/longitude).
  - **Sortie** : coordonnées géographiques utilisables.
- **Application Frontend (ReactJS)** : Ettijahet, développée en React, interagit avec cette API. L'utilisateur saisit une adresse, l'API retourne les coordonnées, puis le moteur de calcul ETA/distance affiche le résultat.
- **Authentification par API Key** : chaque requête envoyée à l'API utilise une clé unique (*API Key*) fournie par la plateforme Armada. Cette clé garantit la sécurité et permet de contrôler l'usage de l'API (quota, suivi des appels).

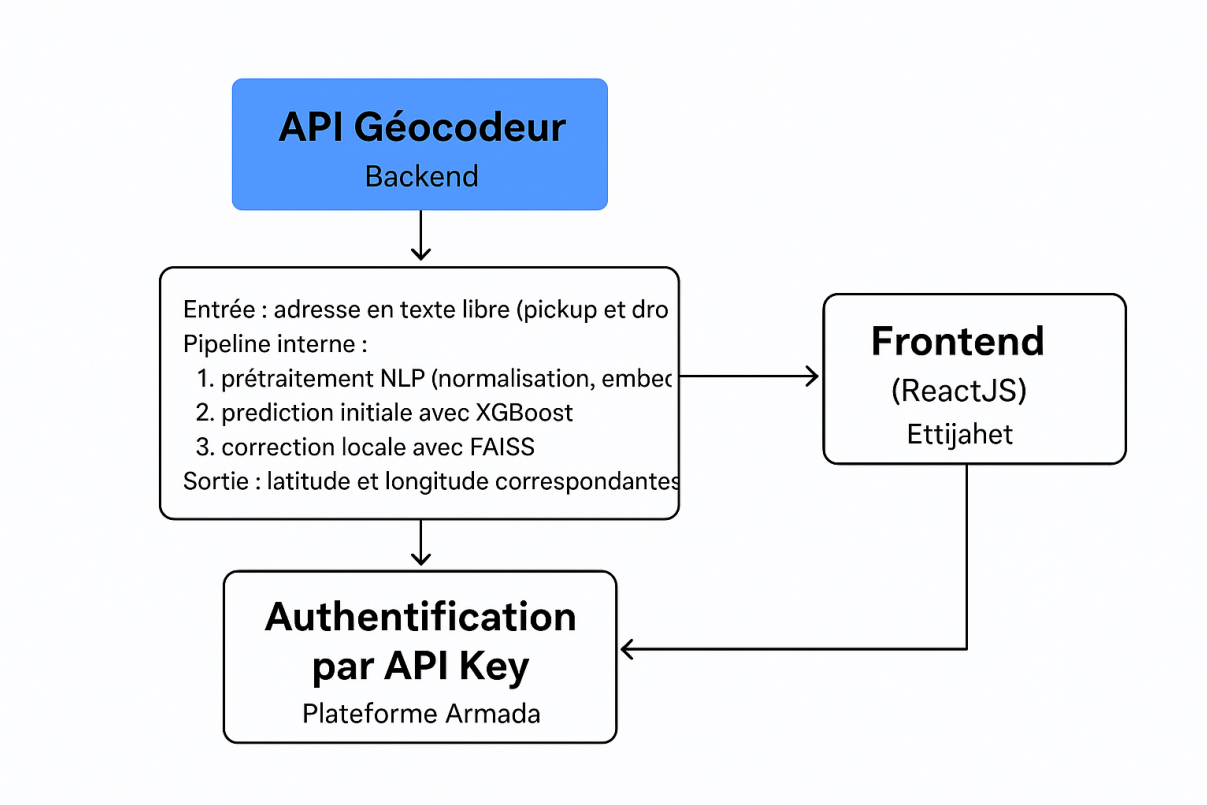


FIGURE 6.1 – Architecture fonctionnelle du déploiement.

6.3 Scénarios d'utilisation

6.3.1 Avant l'intégration du géocodeur

Dans la première version d'Ettijahet, l'utilisateur devait entrer directement les coordonnées GPS.

Cette approche était peu pratique pour un utilisateur lambda, car elle nécessitait une recherche externe ou l'utilisation d'un autre outil pour obtenir les coordonnées exactes.

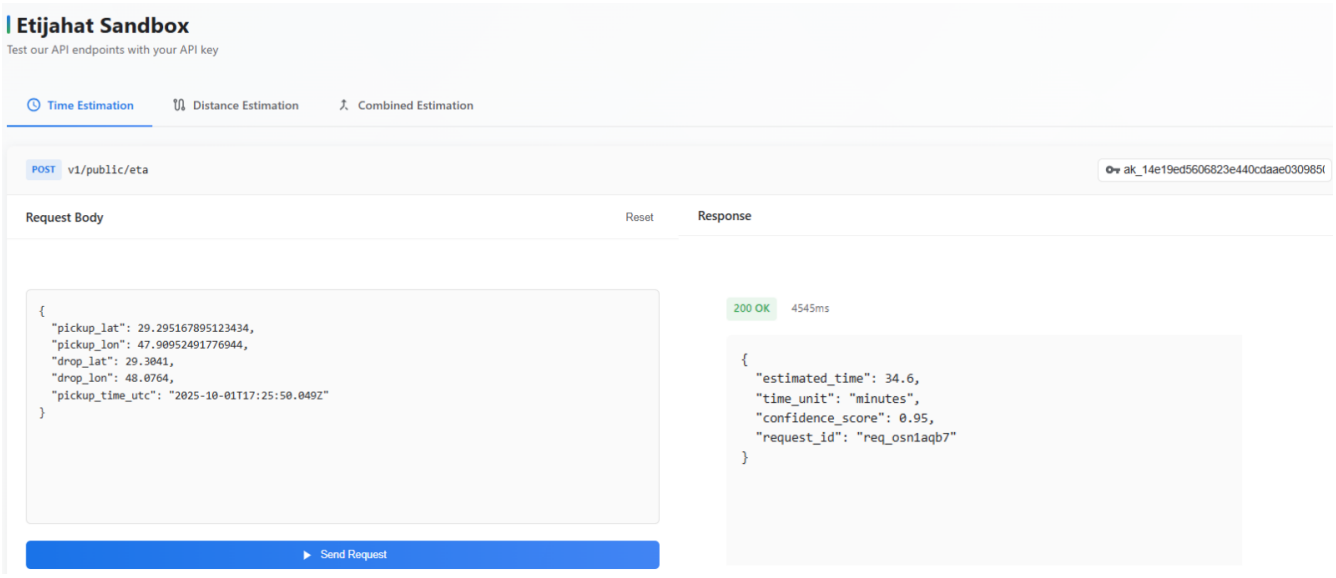


FIGURE 6.2 – Ancienne interface d'Ettijahet : saisie obligatoire des coordonnées GPS.

6.3.2 Après l'intégration du géocodeur

La nouvelle version intègre un **toggle button** qui permet de choisir entre :

— **Mode GPS** : saisie manuelle des coordonnées (ancienne méthode).

— **Mode Adresse** : saisie directe d'adresses textuelles.

Lorsqu'une adresse est saisie, le géocodeur convertit automatiquement le texte en latitude et longitude, puis le moteur calcule l'ETA et la distance.

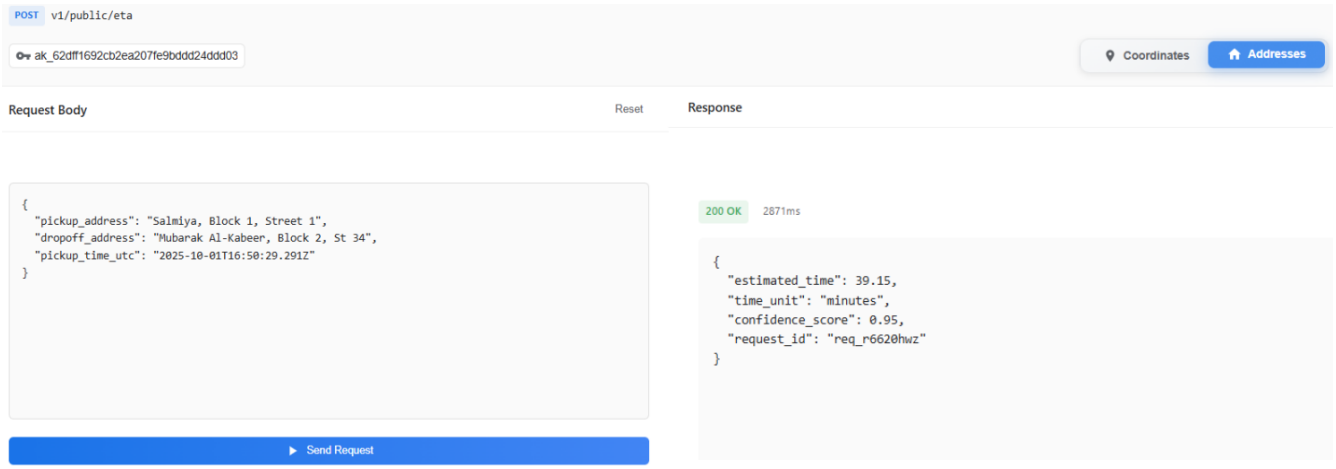


FIGURE 6.3 – Nouvelle interface d'Ettijahet : saisie textuelle des adresses avec bascule (toggle) entre GPS et adresses.

6.4 Appels API et réponses

L'intégration repose sur des appels simples au service API :

— `POST /geocode` : transforme une adresse en coordonnées GPS.

— `POST /eta` : calcule ETA et distance entre pickup et drop (sous forme de texte ou coordonnées).

Exemple de réponse JSON renvoyée par l'API :

```
{
   "estimated_time": 34.6,
   "time_unit": "minutes",
   "confidence_score": 0.95,
   "request_id": "req_osn1aqb7"
}
```

Ce retour inclut non seulement l'estimation du temps, mais aussi un score de confiance permettant d'évaluer la fiabilité de la prédiction.

6.5 Bénéfices concrets du déploiement

— **Expérience utilisateur améliorée** : plus besoin de rechercher ou saisir des coordonnées GPS.

— **Accessibilité** : tout utilisateur peut entrer une adresse naturelle, en arabe ou en anglais.

— **Fiabilité opérationnelle** : l'intégration du géocodeur améliore la précision de la prédiction.

— **Adoption facilitée** : une interface plus intuitive encourage l'utilisation de l'application.

6.6 Conclusion

Le déploiement du géocodeur dans Ettijahet marque une transition réussie vers un usage réel, rendant l'application plus accessible et efficace.

Il ouvre la voie à des améliorations futures comme l'extension géographique ou l'intégration de données en temps réel.

Conclusion Générale

Ce mémoire a porté sur la **modélisation et le déploiement d'un géocodeur basé sur le Machine Learning** pour améliorer la précision de la prédiction des distances et des temps estimés d'arrivée (*ETA*) dans le cadre du *last-mile delivery* au Koweït.

La méthodologie **CRISP-DM** a guidé l'ensemble du projet. La phase de **Business Understanding** a mis en évidence les spécificités du marché koweïtien : multilinguisme, absence de standardisation des adresses et usage de repères locaux.

La **compréhension** et la **préparation des données** ont permis de nettoyer et d'enrichir le dataset grâce à des encodages spatiaux, des pondérations et des représentations textuelles comme TF-IDF et embeddings.

La phase de **modélisation** a évalué deux approches principales : un **Enhanced XGBoost** et un **Hybrid XGBoost + FAISS**. Le modèle hybride s'est révélé le plus performant, atteignant une précision médiane inférieure à 60 mètres et un taux de 64% des adresses géocodées à moins de 100 m.

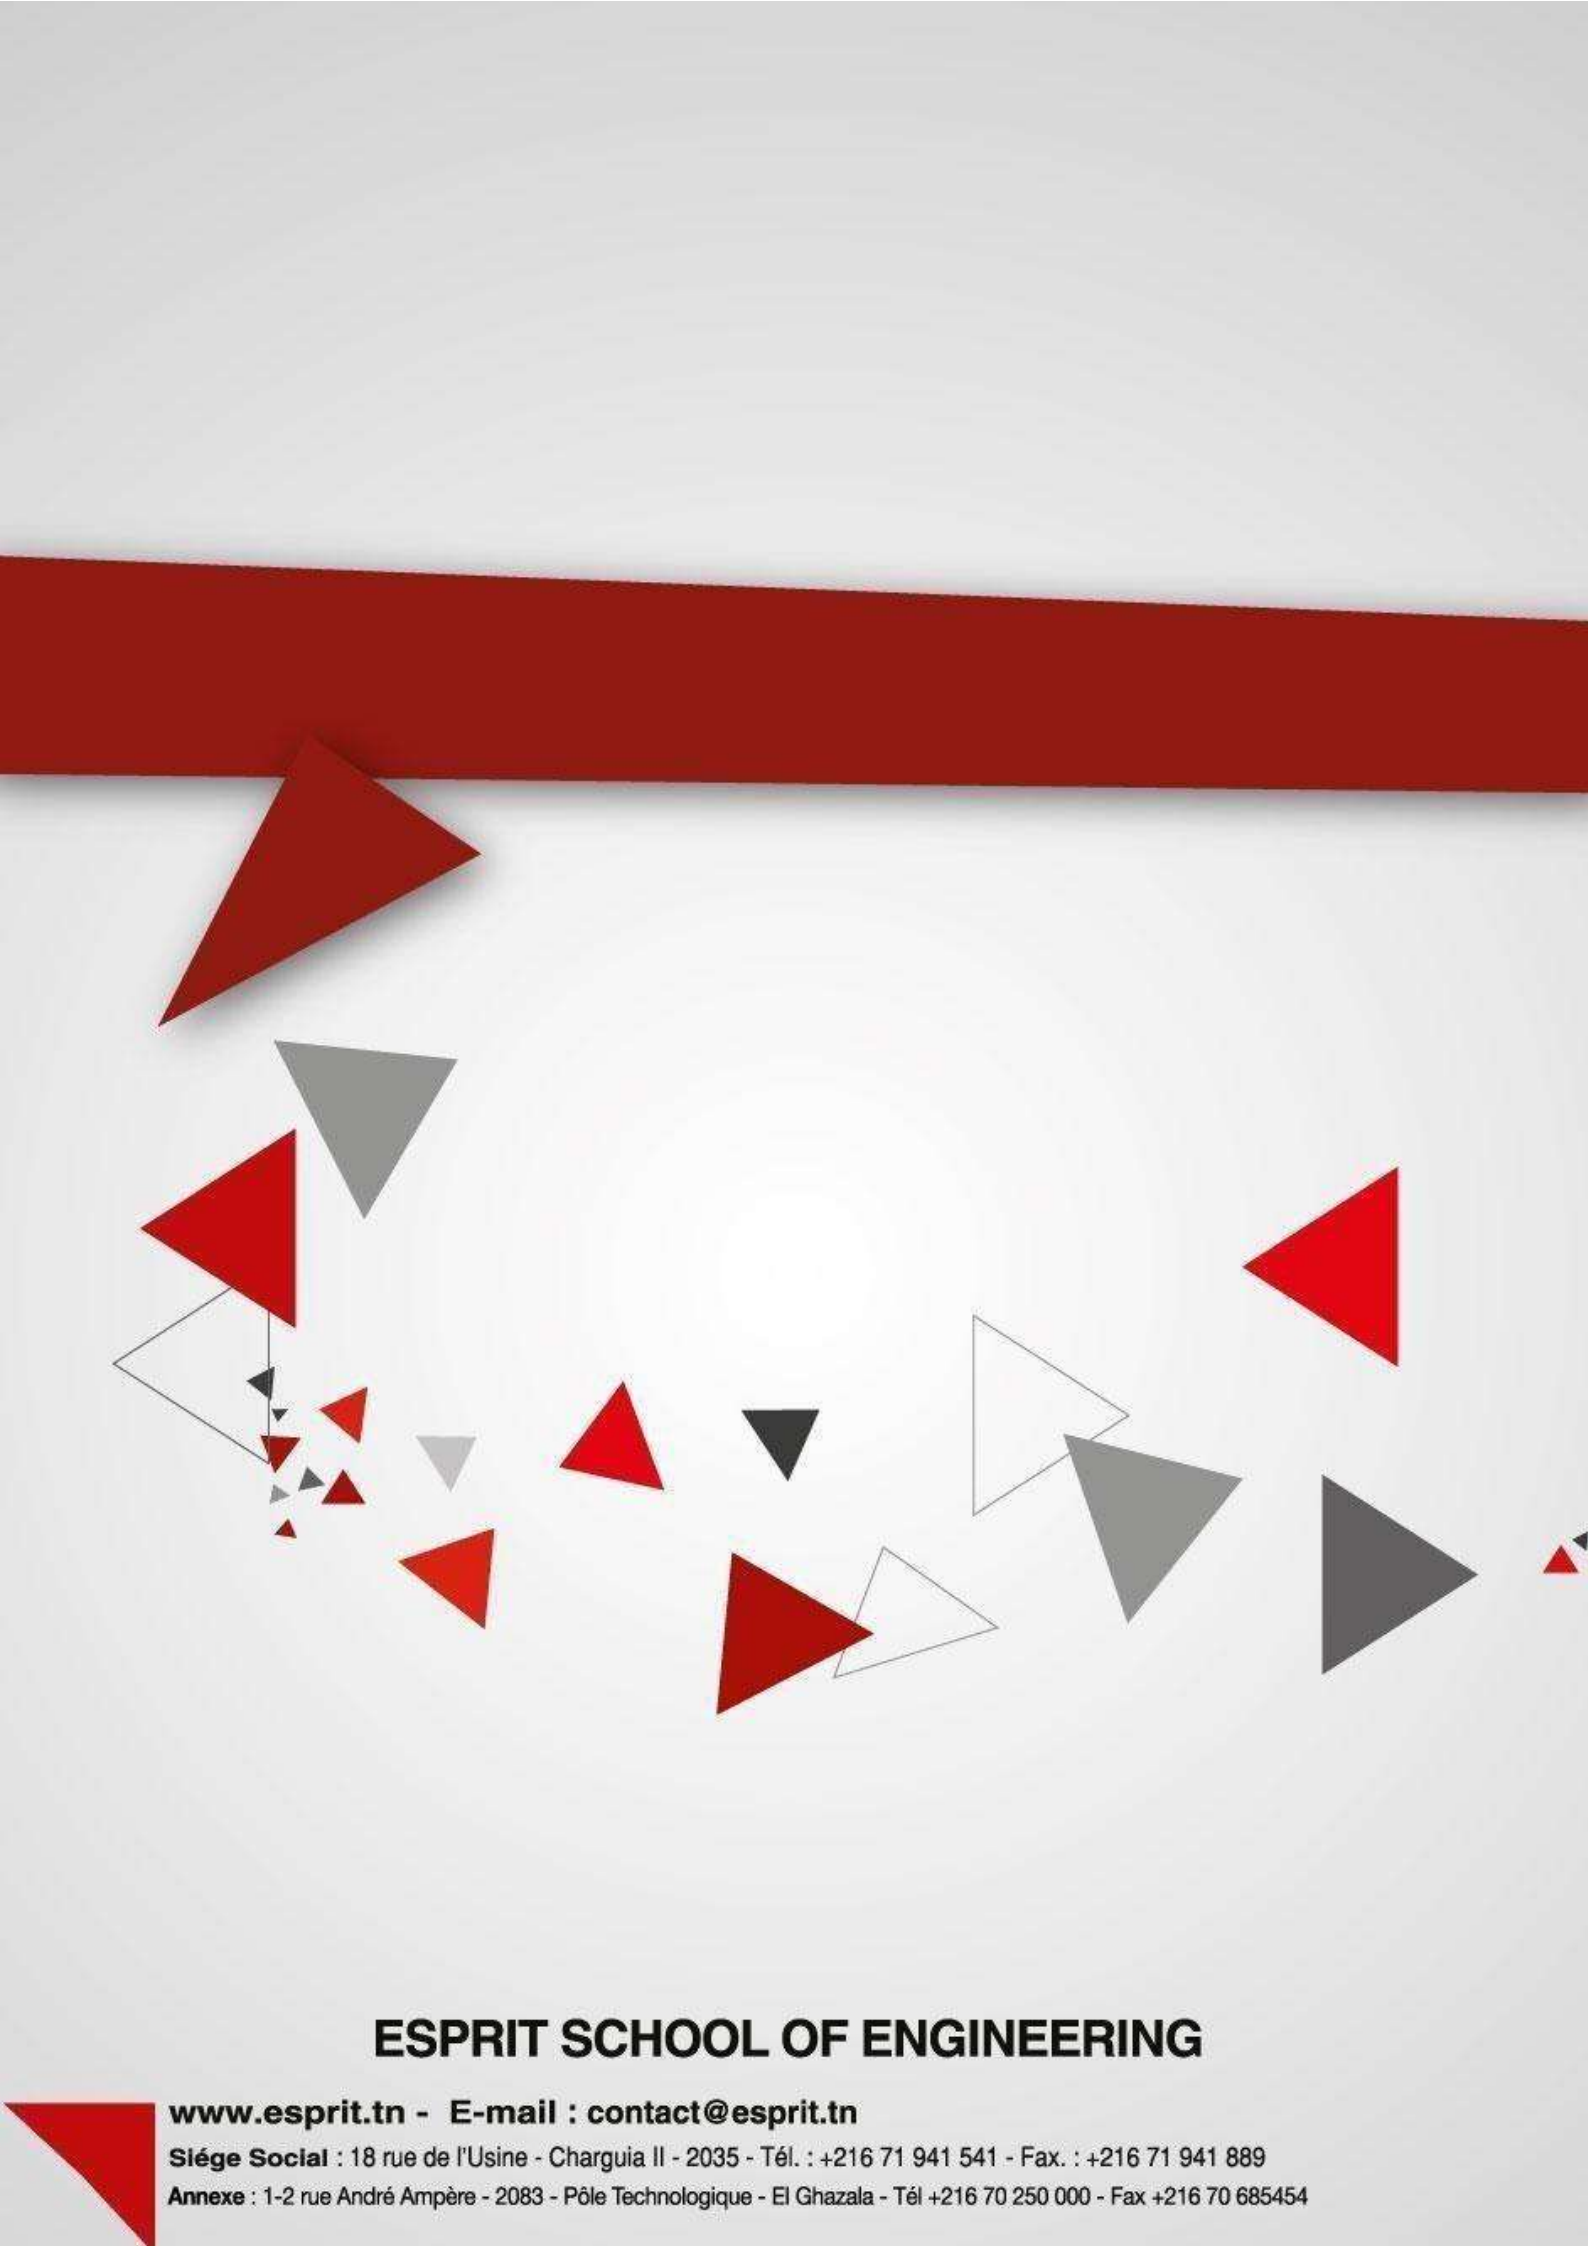
Le **déploiement** dans l'application **Ettijahet** a marqué une avancée majeure : la saisie d'adresses textuelles remplace désormais celle des coordonnées GPS, simplifiant l'expérience utilisateur et rendant le service plus efficace.

Ce projet confirme que la qualité des données est déterminante, que les techniques de **NLP** améliorent fortement les modèles, et que les métriques d'évaluation doivent toujours être adaptées aux besoins métier.

Parmi les perspectives, l'intégration de **Large Language Models (LLMs)**, l'extension à d'autres pays et l'adoption d'un apprentissage in-

crémental pourraient encore renforcer le système.

En définitive, ce travail démontre la capacité de la **Data Science appliquée à la logistique** à transformer des contraintes complexes en solutions concrètes et utiles pour les entreprises.



ESPRIT SCHOOL OF ENGINEERING

www.esprit.tn - E-mail : contact@esprit.tn

Siége Social : 18 rue de l'Usine - Charguia II - 2035 - Tél. : +216 71 941 541 - Fax. : +216 71 941 889

Annexe : 1-2 rue André Ampère - 2083 - Pôle Technologique - El Ghazala - Tél +216 70 250 000 - Fax +216 70 685454